



Treball Final de Grau

Grau en Matemàtica Computacional i Anàlisi de Dades

Analitzant malalties neurològiques des de la perspectiva de la teoria de grafs

Judit Yebra Valencia

Supervisor

Jordi Casas-Roma i Carlos Boned Riera

Any

2024

Convocatòria

Setembre

*A totes les noies en una carrera de ciències,
sí que pertanyeu aquí*

Abstract

This project has the primary objective of investigating the alterations in brain connectivity among patients diagnosed with multiple sclerosis (MS) and how these changes correspond to the cognitive condition of the patients. The research will use magnetic resonance imaging (MRI) data obtained from the Hospital Clínic de Barcelona, and afterwards also data obtained from Naples, Italy, to analyze the structural connectivity of the brain in both MS patients and healthy individuals which will be referred as patients and control.

The motivation behind this project stems from the potential to identify distinct patterns of brain connectivity associated with MS, which could facilitate the monitoring of each patient's condition and potentially predict the progression of the disease on an individual level. The proposed methodology involves employing graph theory to model and examine the MRI images. What this approach aims to ascertain is whether there are specific connectivity patterns linked to the disease or not.

As added in the bibliography, the project idea is supported by three scientific articles that have addressed similar issues using various techniques, including topological data analysis, multiplex networks and classification utilizing support vector machines (SVM), with the help of graph theory. This project aims to expand upon and apply some of these methodologies within the context of multiple sclerosis.

Resum

Aquest projecte té com a objectiu principal investigar les alteracions en la connectivitat cerebral entre els pacients diagnosticats amb esclerosi múltiple (EM) i com aquests canvis corresponen a la condició cognitiva dels pacients. La recerca utilitzarà dades de ressonància magnètica (IRM) obtingudes de l'Hospital Clínic de Barcelona i posteriorment també de Nàpols, Itàlia, per analitzar la connectivitat estructural del cervell tant en pacients amb EM com en individus sans, que seran referits com a pacients i control.

La motivació darrere d'aquest projecte prové del potencial per identificar patrons distints de connectivitat cerebral associats amb l'EM, el que podria facilitar el seguiment de la condició de cada pacient i potencialment predir la progressió de la malaltia a nivell individual. La metodologia proposada implica l'ús de la teoria de grafs per modelar i examinar les imatges d'IRM. El que aquest enfocament pretén assolir és determinar si hi ha patrons de connectivitat específics vinculats a la malaltia o no.

Com s'ha afegit a la bibliografia, la idea del projecte està suportada per tres articles científics que han tractat temes similars utilitzant diverses tècniques, incloent l'anàlisi de dades topològiques, xarxes múltiplex i la classificació utilitzant màquines de vector de suport (SVM), amb l'ajuda de la teoria de grafs. Aquest projecte té com a objectiu expandir i aplicar algunes d'aquestes metodologies dins del context de l'esclerosi múltiple.

Preface

Aquest treball de final de grau es centra en l'estudi de les connexions cerebrals en pacients amb esclerosi múltiple (EM) i la seva relació amb les capacitats cognitives d'aquests pacients. Mitjançant l'anàlisi de dades de ressonància magnètica obtingudes a l'Hospital Clínic de Barcelona i a un hospital de Nàpols, es pretén identificar patrons de connectivitat cerebral que puguin diferenciar els pacients d'individus sans.

L'interès en aquest projecte neix de la possibilitat de trobar noves formes de comprendre l'impacte de l'EM en el cervell, utilitzant eines com la teoria de grafs per modelar i analitzar la complexitat de les dades obtingudes. Aquest enfocament ofereix una perspectiva única que podria contribuir significativament al camp de la neurologia.

El treball es divideix en diverses parts, que inclouen una revisió de la literatura existent, la descripció de la metodologia emprada, l'anàlisi dels resultats i la discussió de les conclusions. L'ús de tècniques com la teoria de grafs, la classificació amb màquines de vector de suport (SVM) i la regressió logística permet aprofundir en l'estudi dels canvis estructurals en el cervell relacionats amb l'EM. Posteriorment s'ha fet també ús d'*embeddings* i de *graph neural networks*.

Vull expressar el meu agraïment als meus tutors, Jordi Casas-Roma i Carlos Boned Riera, pel seu suport i guia durant tot aquest procés, així com a totes les persones que m'han ajudat d'una manera o altra. Aquest projecte representa la culminació del meu esforç acadèmic i espero que reflecteixi l'aprenentatge d'aquests anys.

Barcelona, Setembre 2024

Judit Yebra Valencia

Contents

Abstract	3
Resum	4
Preface	5
Contents	6
1 Introducció i marc teòric	9
1.1 Context del treball	9
1.1.1 Esclerosi múltiple	9
1.1.2 Fractional Anisotropy	10
1.1.3 Gray Matter	10
1.1.4 Resting State (RS)	11
1.2 Objectius	11
1.3 Estructura del document	12
2 Estat de l'art	13
2.1 Machine Learning	13
2.1.1 Support Vector Machines (SVM)	14
2.1.2 Logistic Regression	16
2.2 Graph learning	17
2.2.1 Embeddings de nodes	18
2.2.2 Random walk	19
2.2.3 DeepWalk	20
2.2.4 GNN	21
3 Dades	27
3.1 Cohort i MRI	27
3.2 Processament de les dades	28
3.2.1 Creació dels grafs	28
3.2.2 NetworkX	28
4 Metodologia	30
4.1 Mètodes d'anàlisi	30
4.1.1 Representació gràfica de les dades i anàlisi descriptiva	31
4.1.2 Mètriques dels grafs	33
4.2 Tècniques de preprocessament	35
4.2.1 Feature Scaling	35
4.2.2 Shuffle	36

4.3	Entrenament dels Models amb els Documents	36
4.4	Creació i entrenament d'embeddings	37
4.5	GCN	37
5	Resultats	43
5.1	Mesures utilitzades	43
5.1.1	Accuracy	43
5.1.2	Precision	44
5.1.3	Recall	44
5.1.4	F1 Score	45
5.2	Models mitjançant mètriques	45
5.2.1	Anàlisi General	45
5.2.2	Anàlisi de nodes de FA	46
5.2.3	Anàlisi de nodes de GM	48
5.2.4	Anàlisi de nodes de RS	49
5.2.5	Anàlisi de grafs de FA	50
5.2.6	Anàlisi de grafs de GM	51
5.2.7	Anàlisi de grafs de RS	52
5.3	Embeddings	53
5.3.1	Word2Vec	53
5.3.2	Node2Vec	54
5.4	GCN	55
5.4.1	Anàlisi de nodes	55
5.4.2	Anàlisi de grafs	56
5.4.3	Embeddings Word2Vec i Node2Vec	56
6	Conclusions	57
7	References	59
A	CODI	63

Chapter 1

Introducció i marc teòric

1.1 Context del treball

1.1.1 Esclerosi múltiple

L'esclerosi múltiple (EM) és una malaltia neurològica crònica que afecta el sistema nerviós central, especialment el cervell i la medul·la espinal. Aquesta malaltia es caracteritza per la desmielinització, un procés on la mielina, la capa protectora que envolta les fibres nervioses, és danyada. Això provoca una interrupció en la comunicació entre el cervell i la resta del cos, la qual cosa pot conduir a una àmplia gamma de símptomes, incloent-hi problemes motors, visuals, sensorials i cognitius.

Els símptomes de l'esclerosi múltiple poden variar àmpliament entre els individus i poden incloure fatiga, dificultat per caminar, problemes de visió, espasticitat muscular, problemes d'equilibri i coordinació, dolor, i problemes cognitius i emocionals. Aquests símptomes poden aparèixer i desaparèixer en períodes coneguts com a brots, seguit de períodes de remissió, o poden empitjorar de manera progressiva amb el temps, segons el tipus d'esclerosi múltiple.

Com s'ha vist hi ha diferents tipus d'esclerosi múltiple, que en el treball estan classificats en tres subtipus de la malaltia i en voluntaris sans o controls, que són els zeros. Aquests tres subtipus són els següents: la RRMS, la SPMS, i la PPMS. Cada tipus té característiques clíniques i trajectòries diferents:

- ***Relapsing-Remitting Multiple Sclerosis, RRMS:*** És el tipus més comú i es caracteritza per brots clarament definits de nous símptomes o agreujament dels símptomes existents, seguits per períodes de remissió parcial o completa.
- ***Secondary Progressive Multiple Sclerosis, SPMS:*** Aquesta forma sol desenvolupar-se en pacients que inicialment tenen RRMS. En SPMS, hi ha una progressió constant de la discapacitat amb brots superposats o sense.
- ***Primary Progressive Multiple Sclerosis, PPMS:*** És una forma menys comuna, caracteritzada per una progressió constant de la discapacitat des del començament on no es produeixen períodes de remissió.

El diagnòstic precoç i la classificació precisa dels tipus d'EM són crucials per proporcionar un tractament adequat i millorar la qualitat de vida dels pacients. Les tècniques tradicionals de diagnòstic inclouen la ressonància magnètica (MRI), l'anàlisi del líquid cefalorraquidi

mitjançant punció lumbar, i les proves neurofisiològiques. El problema que hi ha és que aquestes tècniques poden ser invasives, costoses, i en alguns casos, no prou precises per detectar les diferències subtils entre els tipus d'esclerosi múltiple en les primeres etapes de la malaltia.

Motiu pel qual hi ha un interès creixent en el desenvolupament de mètodes no invasius basats en dades per millorar la precisió del diagnòstic. Les mètriques de grafs, que analitzen la connectivitat cerebral, ofereixen una oportunitat prometedora per identificar patrons específics associats amb diferents tipus d'EM. Aquest enfocament permet una comprensió més profunda de les alteracions en la xarxa neuronal i pot contribuir a diagnòstics més precisos i accelerats.

1.1.2 Fractional Anisotropy

L'anisotropia fraccional (en anglès, *fractional anisotropy*, FA), és una mesura que es deriva de les imatges de difusió per ressonància magnètica (DTI). Aquesta tècnica permet mesurar el moviment de les molècules d'aigua en el teixit cerebral. L'anisotropia fraccional mesura la direccionalitat del moviment de l'aigua, la qual cosa proporciona informació sobre la integritat de les fibres de matèria blanca en el cervell.

Aquest moviment de les molècules d'aigua es veu restringit per les membranes cel·lulars i altres estructures microscòpiques, i aquest moviment és comunament més restringit en una direcció en comparació amb altres. L'anisotropia fraccional proporciona un valor entre 0 i 1, on 0 indica que el moviment de l'aigua és igual en totes les direccions (isotròpic) i 1 indica que el moviment és totalment restringit a una direcció (anisotròpic). Aquesta mesura és útil per avaluar si les vies de matèria blanca estan danyades per alguna malaltia neurològica.

Les fibres de matèria blanca connecten diferents regions del cervell, i que no estiguin danyades és essencial per a la comunicació neuronal efectiva. En pacients amb esclerosi múltiple, la desmielinització i el dany axonal poden afectar l'anisotropia fraccional, la qual cosa fa que sigui una mesura valuosa per a l'efectuació de l'estudi d'aquesta malaltia.

1.1.3 Gray Matter

La substància grisa (en anglès, *grey matter*, GM) és un tipus de teixit cerebral que conté la major part dels cossos neuronals, dendrites, i terminals axonals, així com cèl·lules, com per exemple, les cèl·lules glials (cèl·lules del sistema nerviós) i capil·lars. La substància grisa es troba principalment a la superfície del cervell, és a dir, al còrtex cerebral i en diverses estructures profundes.

El còrtex cerebral és responsable de moltes funcions complexes, incloent-hi la percepció sensorial, el pensament, el raonament i el moviment voluntari. Les alteracions a la substància grisa poden afectar aquestes funcions i estan implicades en diverses malalties neurològiques.

En el context de l'esclerosi múltiple, la pèrdua de volum de substància grisa és un marcador important de la progressió de la malaltia. L'anàlisi de la substància grisa permet identificar aquestes pèrdues mitjançant tècniques d'imatge per ressonància magnètica i correlacionar-les amb els símptomes clínics i el curs de la malaltia.

1.1.4 Resting State (RS)

L'estat de repòs (en anglès, *resting state*, RS) es refereix a l'activitat cerebral que es mesura mentre el subjecte està, com indica el seu nom, en un estat de repòs, és a dir, no aconsegueix cap tasca específica.

La imatge per ressonància magnètica funcional (fMRI) en estat de repòs és una tècnica utilitzada per examinar la connectivitat funcional del cervell, ja que detecta els canvis en el flux sanguini cerebral associats amb l'activitat neuronal. Aquesta tècnica permet identificar xarxes neuronals que es mantenen actives de manera coherent durant el repòs.

En l'esclerosi múltiple, la connectivitat funcional pot estar alterada, i l'anàlisi de l'estat de repòs pot revelar patrons específics de desconexió entre regions cerebrals. Això pot proporcionar informació molt valuosa sobre el funcionament de la malaltia i les seves manifestacions a les diferents regions del cervell.

1.2 Objectius

El present treball final de grau s'ha articulat al voltant de diversos objectius que han estat fonamentals per a la seva realització. Els objectius principals han estat:

1. El primer objectiu primari és la investigació de les alteracions en la connectivitat cerebral en pacients amb esclerosi múltiple, centrada en l'anàlisi exhaustiva de les alteracions que es produeixen en les xarxes neuronals dels pacients diagnosticats amb aquesta malaltia, utilitzant teoria de grafs i aprenentatge automàtic basat en grafs (*graph learning*, en anglès).
2. El segon propòsit fonamental és l'anàlisi de la variabilitat en els resultats segons les tècniques i canvis en les dades, explorant com diferents tècniques i ajustaments en les dades influeixen en els resultats obtinguts en la predicció de si són pacients o controls.

Per altra banda, es defineixen també un conjunt d'objectius secundaris, derivats dels primaris o necessaris per complir els primaris, que permeten completar la tasca global associada al projecte:

3. Entendre i processar les dades derivades d'imatges de ressonància magnètica (*magnetic resonance images*, MRI) per poder ser analitzades emprant tècniques d'anàlisi de dades i aprenentatge automàtic.
4. Estudiar i aplicar els mètodes d'extracció de característiques que permeten generar representacions rellevants de la informació continguda en els grafs.
5. Comprendre i implementar models avançats d'aprenentatge basat en grafs, tals com les *graph neural networks* (GNN), per millorar el rendiment predictiu en dades semiestructurades en format de grafs.

D'aquesta manera, l'estudi no només contribueix al coneixement científic en l'àmbit de la neurociència, sinó que també ofereix noves perspectives a la pràctica d'utilitzar mètodes d'aprenentatge automàtic a la medicina moderna.

1.3 Estructura del document

Primerament, al capítol 1 hi ha la continuació del resum on es presenta el context del treball amb nomenclatura i les seves definicions importants per poder seguir-lo, aquestes inclouen l'esclerosi múltiple, l'anisotropia fraccional, la substància grisa i l'estat de repòs. A continuació en aquest mateix capítol es detallen els objectius del treball els quals ja es mencionaven en el resum o *abstract* però de forma més extensa.

El capítol 2 inclou una explicació de com funcionen i que són realment els diferents models de *Machine Learning* que s'han utilitzat al treball, entre els quals s'inclouen la màquina de suport vectorial (SVM) i la regressió logística. En la segona part del capítol es defineixen i s'explica el funcionament de tècniques avançades en el camp de l'aprenentatge automàtic i el processament de dades estructurades en forma de grafs com poden ser el *RandomWalk*, el *DeepWalk* o les GNN.

En el capítol 3 es detallen les diferents dades que s'han utilitzat per a aquest projecte el seu treball i la seva estructura. En la primera secció s'expliquen les diferents dades generals com poden ser els pacients i els controls, informació important sobre ells, i les dades FA, RS i GM. També s'explica com s'han unit les dades obtingudes de dues fonts diferents. En la segona secció com indica el seu nom es parla sobre processament de les dades, és a dir, com es converteixen les matrius a graf i quins filtres s'apliquen.

El capítol 4 es centra en la descripció de la metodologia, i es divideix en quatre seccions: la descripció general de la metodologia, les diferents mètriques de teoria de grafs, els *embeddings* amb *RandomWalk* i *DeepWalk* i per últim les GNN. Aquest capítol segueix la mateixa estructura que el treball i comenta tots els passos que s'han fet al codi de forma resumida i utilitzant els conceptes que s'han definit anteriorment.

El capítol 5 presenta els resultats detallant quina ha estat la resposta de cadascun dels passos que s'han anat explicant a la metodologia i seguint al treball.

Finalment, al capítol 6, es discuteixen les conclusions on es resumeixen les principals claus obtingudes i es proposen futures línies de recerca.

Chapter 2

Estat de l'art

2.1 Machine Learning

El *Machine Learning*, o en català, aprenentatge automàtic, és una branca de la intel·ligència artificial que se centra en el desenvolupament d'algorismes i models que permeten als ordinadors aprendre a partir de dades i fer prediccions o prendre decisions sense ser programats explícitament per a cada tasca. Aquests models analitzen grans volums de dades, identifiquen patrons i ajusten les seves prediccions en funció de l'experiència, millorant amb el temps i amb l'acumulació de dades. L'aprenentatge automàtic s'aplica en àrees com la visió per computador, el processament del llenguatge natural, i els sistemes de recomanació, entre altres.

Els models de *Machine Learning* són algorismes o conjunts d'algorismes dissenyats per a aprendre patrons a partir de dades. L'objectiu d'aquests models és fer prediccions o prendre decisions basades en noves dades, utilitzant el coneixement adquirit durant la fase d'entrenament.

Aquests models poden ser de diferents tipus d'aprenentatge:

- **Aprenentatge Supervisat:** aprenen a partir d'un conjunt de dades etiquetades, on cada exemple d'entrenament està associat amb una etiqueta o resultat esperat. Són molt útils per a fer classificació, com era necessària en aquest cas.
- **Aprenentatge No Supervisat:** treballen amb dades sense etiquetar, buscant estructures o patrons ocults en les dades. Són molt útils per fer *clustering*, és a dir, agrupar dades segons les seves similituds.
- **Aprenentatge Semi-Supervisat:** combina un petit conjunt de dades etiquetades amb un gran conjunt de dades sense etiquetar. L'objectiu és millorar la precisió de l'aprenentatge utilitzant tant dades etiquetades com sense etiquetar. És una barreja entre l'aprenentatge supervisat i el no supervisar i és molt útil per classificar grans dades on només hi ha una part etiquetada.
- **Aprenentatge per Reforç:** implica un agent que aprèn a prendre decisions mitjançant la interacció amb un entorn, rebre recompenses o penalitzacions per les accions que realitza, i millorar les seves decisions al llarg del temps.

2.1.1 Support Vector Machines (SVM)

Les màquines de vector de suport són un algorisme d'aprenentatge automàtic supervisat, ja que aprèn a partir d'un conjunt de dades etiquetades, on cada exemple d'entrenament està associat amb una etiqueta o classe coneguda. És utilitzat per a tasques de classificació i regressió. L'objectiu principal d'una SVM és trobar un hiperplà òptim que separi les diferents classes en un espai de característiques. L'algorisme només pot trobar aquest hiperplà en problemes que permeten la separació lineal; en la majoria dels problemes pràctics, l'algorisme maximitza el marge flexible permetent un petit nombre de classificacions errònies. Aquest hiperplà es selecciona per maximitzar la distància (marge) entre els punts de dades de les diferents classes més propers, coneguts com a vectors de suport.

El concepte de les màquines de vectors de suport va ser introduït per Vladimir Vapnik i el seu amic Alexey Chervonenkis. No obstant això, el primer article en què es va presentar formalment el SVM va ser escrit per Vladimir Vapnik en col·laboració amb Corinna Cortes l'any 1995 a la revista *Machine Learning Journal*, aquest paper s'anomena Support-vector networks i va establir les bases per a l'ús de les SVM en la classificació de dades i és considerat una peça clau en el camp de l'aprenentatge automàtic.




Figure 2.1: Teoria de la SVM. Font: MathWorks

En la figura 2.1 es pot observar com l'algorisme intenta separar dues classes diferents de dades, representades per símbols $+$ i $-$, utilitzant una línia divisòria que és l'hiperplà separador. Aquest hiperplà separador, representat per una línia blava contínua al centre de la imatge, és la frontera que divideix les dues classes de dades. És, per tant, l'objectiu principal de l'algorisme SVM trobar l'hiperplà que separi les dues classes amb el màxim marge possible. Aquest marge és la distància entre l'hiperplà separador i els punts de dades més propers a ell, que són coneguts com a vectors de suport.

Els vectors de suport, marcats a la imatge, són els punts de dades més propers a l'hiperplà i són especialment importants perquè determinen la posició exacta de l'hiperplà. Les línies discontinuïtes blaves que passen per aquests vectors de suport defineixen els límits del marge. L'algorisme busca maximitzar aquest marge, perquè com més gran sigui, més clara i robusta serà la separació entre les dues classes.

L'algorisme SVM estàndard està formulat per a problemes de classificació binària; els problemes multiclasse normalment es redueixen a una sèrie de problemes binaris. Les SVM són especialment efectives en espais d'alta dimensió i destaquen per la seva utilitat en situacions on el nombre de dimensions és superior al nombre de mostres.

Les SVM són famosament útils perquè poden utilitzar diferents funcions de nucli (*kernel functions*) les quals assignen les dades a un espai dimensional diferent, que sovint és superior, amb l'expectativa que resulti més fàcil separar les classes després d'aquesta transformació, simplificant potencialment els límits de decisió complexos no lineals per fer-los lineals en l'espai dimensional de característiques superior assignat. En aquest procés, no cal transformar explícitament les dades, ja que això suposaria una alta càrrega computacional. Aquest mètode és conegut com el truc del nucli (*kernel trick*).

Hi ha diferents tipus de màquines de vector de suport segons la seva finalitat:

- **SVM Lineal:** s'utilitza quan les dades són linealment separables, és a dir, es pot traçar una línia (o un hiperplà en dimensions superiors) que separa clarament les dues classes. És l'original i, per tant, al qual se li aplica tota la teoria anterior.
- **SVM No Lineal:** s'utilitza quan les dades no són linealment separables. En aquest cas, s'utilitza una funció de nucli (kernel) per transformar les dades en un espai de característiques superior on es poden separar linealment.
- **SVM amb Nucli:** és una extensió de l'SVM que utilitza diferents funcions de nucli per projectar les dades en un espai de característiques de major dimensió, on les dades es poden separar millor. Els nuclis més comunament utilitzats són el nucli lineal, el nucli polinòmic, el nucli radial basis function (RBF) o gaussià i el nucli sigmoide. S'utilitza per tractar problemes on la separació no és possible en l'espai original de les dades, per exemple les dades no es poden separar de forma lineal.
- **SVM de marge suau (soft-margin):** permet algunes violacions de la separació correcta de les dades, és a dir, permet que alguns punts caiguin al costat incorrecte de l'hiperplà. Això és útil quan les dades són sorolloses o no perfectament separables, ja que prefereix un model que generalitzi millor en lloc de separar perfectament totes les dades d'entrenament.
- **SVM de marge dur (hard-margin):** requereix que totes les dades siguin correctament classificades sense cap error. Aquest enfocament només funciona bé si les dades són completament linealment separables i no hi ha soroll. És necessari per fer una classificació exacta.
- **SVM multiclasse:** és una adaptació de l'SVM original, que és de classificació binària, per poder fer classificació multiclasse. Hi ha dos tipus, el One-vs-One (OvO), el qual crea un model SVM per a cada possible parella de classes, i la classe que guanya més comparacions és seleccionada i el One-vs-Rest (OvR), el qual crea un model SVM per a cada classe, on la classe objectiu es compara contra totes les altres classes combinades.
- **Support Vector Regression (SVR):** és una extensió de l'SVM per a tasques de regressió, on l'objectiu és predir un valor continu en lloc de classificar dades en categories.

2.1.2 Logistic Regression

La regressió logística és un model estadístic utilitzat per a tasques de classificació, especialment quan l'objectiu és preveure l'etiqueta de classe binària (per exemple, sí/no o vertader/fals) d'una variable dependent. A diferència de la regressió lineal, que prediu valors continus, la regressió logística estima la probabilitat que una mostra pertanyi a una de les classes, de forma que pot oferir informació addicional sobre la certesa del model.

El model utilitza una funció logística (també coneguda com a funció sigmoide) per *mapejar* qualsevol valor real en un interval comprès entre 0 i 1. La funció logística té la forma:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_n X_n)}}$$

On:

- $(P(Y = 1|X))$ és la probabilitat de l'esdeveniment d'interès.
- $(\beta_0, \beta_1, \dots, \beta_n)$ són els coeficients del model que s'aprenen durant l'entrenament.
- $(X_1, \dots, X_n)$ són les variables independents o característiques.

El primer article que va introduir la regressió logística va ser publicat per David Cox l'any 1958, i s'anomena *The regression analysis of binary sequences*. Aquest article és fonamental en l'estadística i l'anàlisi de dades, ja que presenta la regressió logística com un mètode per modelar la probabilitat d'un esdeveniment binari en funció d'una o més variables independents.




Figure 2.2: Funció sigmoide ajustada a unes dades. Font: Medium

A la figura 2.2 es pot observar la funció sigmoide d'una regressió logística aplicada a unes dades. Com s'ha explicat anteriorment, els models de regressió logística són models de classificació generalment binària motiu pel qual es poden percebre dues categories diferents, aquestes dues categories són dues observacions completament distintes. D'altra banda, l'eix

Y va de 0 a 1 perquè la funció sigmoide sempre té com a màxim i mínim aquests dos valors, cosa que s'adapta molt bé a l'objectiu de classificar mostres en dues categories diferents. En calcular la funció sigmoide de X (que és una suma ponderada de les característiques d'entrada, igual que en la regressió lineal), s'obté una probabilitat (evidentment entre 0 i 1) que una observació pertanyi a una de les dues categories.

Hi ha diferents tipus de regressió logística:

- **Regressió Logística Binària:** és l'original i més bàsica. S'encarrega de problemes de classificació on hi ha dues classes (0 o 1, sí o no, positiu o negatiu, etc.).
- **Regressió Logística Multiclasse (o Multinomial):** és una extensió de la regressió logística binària que s'utilitza quan hi ha més de dues classes. A diferència de la regressió logística binària, aquest tipus de regressió pot manejar múltiples categories simultàniament. Hi ha diferents tipus com el One-vs-Rest (OvR) o One-vs-All (OvA) on es crea un model de regressió logística binària per a cada classe, on la classe objectiu és comparada contra totes les altres classes combinades. Finalment, se selecciona la classe amb la predicció de probabilitat més alta i el Softmax (o Regressió Logística Multinomial) el qual és una extensió natural de la regressió logística que calcula probabilitats per a totes les classes i escull la classe amb la probabilitat més alta. És comú en models de xarxes neuronals.
- **Regressió logística ordinal:** s'utilitza quan les categories tenen un ordre natural, però les distàncies entre les categories no són necessàriament iguals.
- **Regressió logística multi-etiqueta (multilabel):** la regressió logística multi-etiqueta permet que un exemple pertanyi a múltiples classes simultàniament. Això es fa entrenant múltiples models de regressió logística binària, un per cada classe, i cada model prediu si una etiqueta s'aplica o no a un exemple. És útil per a problemes on els elements poden tenir diverses categories alhora, com en classificació de textos o etiquetatge d'imatges.
- **Regressió logística lasso i ridge:** són versions regularitzades de la regressió logística. La regularització s'utilitza per prevenir el sobre ajustament (*overfitting*) i millorar la generalització del model. Hi ha dos tipus la *lasso* (L1) la qual pot portar a la selecció de variables, ja que tendeix a reduir a zero els coeficients de variables menys rellevants i la *ridge* (L2) la qual redueix la magnitud dels coeficients, però no porta a coeficients exactament iguals a zero.

2.2 Graph learning

L'aprenentatge en grafs, o en anglès *graph learning*, és una branca del *machine learning* que se centra en l'anàlisi i interpretació de dades representades en forma de graf. Un graf és una col·lecció de nodes (o vèrtexs) i arestes, on els nodes representen entitats i les arestes les relacions o interaccions entre aquestes entitats. Aquesta estructura és útil per modelar xarxes complexes en àmbits com les xarxes socials, xarxes biològiques i xarxes de comunicació, entre d'altres.

Una xarxa neuronal és un model computacional inspirat en el funcionament del cervell humà, dissenyat per reconèixer patrons i prendre decisions basades en dades. Està formada per capes de neurones artificials (que són els nodes o vèrtex) interconnectades, on cada

connexió té un pes associat. Les dades s'introdueixen a la capa d'entrada, passen per les capes ocultes on es processen, i finalment produeixen un resultat a la capa de sortida. Les xarxes neuronals són àmpliament utilitzades en tasques com reconeixement d'imatges, processament de llenguatge natural i predicció de sèries temporals.

L'aprenentatge en grafs aprofita les relacions i estructures dins del graf per aprendre i fer prediccions, ja que utilitzant l'estructura inherent de les dades en graf, els algorismes d'aprenentatge en grafs poden descobrir coneixements i patrons profunds que no són evidents amb enfocaments tradicionals d'aprenentatge automàtic.

2.2.1 Embeddings de nodes

Els *embeddings* són una tècnica de processament del llenguatge natural que converteix el llenguatge humà en vectors matemàtics. Aquests vectors són una representació del significat subjacent de les paraules, cosa que permet a les computadores processar el llenguatge de manera més efectiva. Els *embeddings* permeten que les paraules siguin tractades com a dades i manipulades matemàticament. Aquesta tècnica s'utilitza àmpliament en la intel·ligència artificial per a tasques com la classificació de text i la traducció automàtica.

El procés de creació d'*embeddings* comença amb la construcció d'un corpus, que és una col·lecció de textos. A partir d'aquest corpus, es crea un model de llenguatge que aprèn a predir paraules segons el seu context. Un cop entrenat el model, s'utilitzen les seves capes internes per generar els vectors d'*embeddings* de les paraules. Els vectors generats pels *embeddings* tenen diverses propietats útils que els fan especialment efectius en aplicacions de processament del llenguatge natural. En primer lloc, els vectors són densos, la qual cosa significa que cadascuna de les seves dimensions conté informació rellevant. En segon lloc, els vectors són similars per a paraules que s'utilitzen en contextos similars, fet que permet utilitzar els *embeddings* per determinar la similitud semàntica entre paraules.

Hi ha diferents tècniques per crear *embeddings*, com per exemple el *Word2vec* i el *Node2vec*. El primer és una tècnica de processament del llenguatge natural que converteix les paraules en vectors numèrics de manera que les paraules que apareixen en contextos similars tinguin representacions vectorials similars. Es basa en dos models principals: CBOW (*Continuous Bag of Words*), que prediu una paraula donat el seu context, i Skip-gram, que prediu el context donat una paraula. Això permet capturar relacions semàntiques entre les paraules, fent-lo molt útil en tasques com la similitud de paraules i la classificació de textos. El segon és una extensió de *Word2Vec* aplicada a grafs. Transforma nodes d'un graf en vectors numèrics d'una manera que preserva les relacions estructurals entre els nodes. Ho fa generant "camins aleatoris" (*random walks*) a través del graf per crear seqüències de nodes, de manera similar a com *Word2Vec* treballa amb seqüències de paraules. Aquestes seqüències s'utilitzen després per entrenar un model que genera *embeddings* que representen cada node, fent-los útils per a tasques com la predicció d'enllaços o la classificació de nodes dins del graf.

Un dels primers articles clau que va introduir el concepte d'*embeddings* de paraules és el treball de Yoshua Bengio i col·laboradors, anomenat A neural probabilistic language model al *Journal of Machine Learning Research* l'any 2003. Aquest article va establir les bases per als desenvolupaments posteriors en tècniques com *Word2Vec*.

El model *Word2vec* va ser introduït per Mikolov et al. en l'article titulat Efficient Estimation of Word Representations in Vector Space el 2013, que presenta un mètode eficient per estimar representacions de paraules en un espai vectorial. D'altra banda, *Node2vec* va ser presentat per Grover i Leskovec en l'article Node2vec: Scalable Feature Learning for Networks l'any 2016, on es proposa un enfocament escalable per a l'aprenentatge de característiques en xarxes. Ambdós mètodes han estat fonamentals en l'avenç de la representació de dades en espais vectorials.

2.2.2 Random walk

Abreviat com RW i anomenat *camí aleatori* en català, el *RandomWalk* és un procés matemàtic que descriu una seqüència de passos aleatoris en algun espai, com ara una línia, un pla, o un graf. En aquest procés, un punt o partícula es mou d'una posició a una altra seguint regles probabilístiques, sense un camí predefinit. Els *random walks* són utilitzats en diverses disciplines, com la física, la biologia, l'economia i la informàtica, per modelar fenòmens que impliquen moviments o decisions aleatòries, com la difusió de partícules o la generació d'estructures de dades.

El concepte de *random walk* o passeig aleatori és un tema clàssic en matemàtiques i probabilitat, amb aplicacions àmplies en àrees com la física, la biologia i les finances. Un dels treballs fonamentals sobre els passeigs aleatoris, anomenat *Über eine Aufgabe der Wahrscheinlichkeitsrechnung betreffend die Irrfahrt im Straßennetz*, va ser publicat per George Pólya l'any 1921. Aquest article va introduir els passeigs aleatoris en un context matemàtic rigorós i és considerat un punt de partida per a molts desenvolupaments posteriors en aquest camp.

Hi ha diferents tipus de *RandomWalk* segons si els passos són igualment probables en qualsevol direcció (*RandomWalk* simple) o si tenen diferents probabilitats (*RandomWalk* biaixat), també pot ser que els moviments estiguin restringits per certes condicions (*RandomWalk* constrained), si aquesta restricció és concretament que la caminada no pot passar per una posició que ja ha estat visitada anteriorment, llavors s'anomena *self-avoiding walk*, si, en canvi, es restringeix a una xarxa discreta s'anomena *lattice RandomWalk*, finalment el *brownian motion* modela el moviment de partícules en un fluid. Aquest tipus de procés també es fa servir en simulacions estadístiques i en algorismes de cerca i navegació per Internet. A més, els *random walks* tenen propietats estadístiques importants, com la convergència cap a una distribució normal en certs casos, la qual cosa els fa valuosos en l'anàlisi i modelatge de fenòmens més complexos.

Els *RandomWalks* poden ser en 1D, 2D, 3D. Comunament són més utilitzats els 2D, ja que són àmpliament utilitzats en l'estudi de la mobilitat. És un patró de moviment sense memòria on la velocitat actual és independent de la passada, però també pot generar moviments poc realistes, com parades sobtades i girs bruscos.

A la figura 2.3 es pot observar un exemple de *random walk* en un pla bidimensional. Aquesta imatge mostra una seqüència de passos aleatoris que es mouen en diverses direccions en un pla. La posició inicial i la posició final es marquen clarament, i les fletxes indiquen la direcció i l'ordre dels passos. Comença en una posició inicial marcada i es mou en una sèrie de 10 passos en diverses direccions, cadascun indicat per fletxes numerades. Les fletxes representen la direcció i l'ordre de cada moviment, mentre que la posició final és clarament




Figure 2.3: Exemple de RandomWalk. Font: GeeksforGeeks

indicada. Aquesta visualització mostra com un punt es desplaça aleatòriament sense seguir un camí predeterminat, un concepte central en l'estudi de les caminades aleatòries.

2.2.3 DeepWalk

El *DeepWalk* és un algorisme que aprèn representacions latents de nodes en un graf utilitzant caminades aleatòries truncades i posteriorment utilitza l'algorisme *Word2Vec* per aprendre les representacions dels nodes. Inspirat en tècniques de modelatge de llenguatge, tracta aquestes caminades aleatòries com si fossin "frases" en un llenguatge, cosa que permet capturar la informació estructural del graf. *DeepWalk* genera aquestes representacions vectorials per als nodes, que poden ser utilitzades en tasques com la classificació de nodes, especialment en contextos de xarxes socials. L'algorisme és escalable i eficient, sent capaç de manejar grafs de gran escala i obtenir millors resultats que altres mètodes en situacions amb dades etiquetades escasses.

El *DeepWalk* és una tècnica innovadora per a l'aprenentatge d'*embeddings* en grafs, introduïda per primera vegada en un article de Bryan Perozzi, Rami Al-Rfou, i Steven Skiena l'any 2014, anomenat DeepWalk: Online learning of social representations. Van ser els creadors de combinar els *random walks* amb models d'aprenentatge profund per generar representacions vectorials dels nodes en un graf, que permet aplicar tècniques d'aprenentatge automàtic en estructures de xarxes complexes.

A la figura 2.4, es pot observar un exemple de *DeepWalk*. Aquesta imatge il·lustra de manera esquemàtica el flux de treball de l'algorisme, des de la generació de caminades aleatòries fins a la creació dels *embeddings* utilitzant *Word2Vec*. La imatge comença mostrant una xarxa o graf, on els nodes estan connectats per arestes a l'apartat (a). Aquest graf és la base sobre la qual es fan les *random walks*. Posteriorment, a l'apartat (b) es mostren diferents estratègies de caminada aleatòria que es poden emprar a partir dels nodes del graf. Aquestes caminades aleatòries exploren les connexions locals del graf, movent-se d'un node a un altre en funció de les connexions disponibles. Això ajuda a capturar les relacions locals entre els nodes. A l'apartat (c) els *random walks* generats s'utilitzen com a entrada per al model *Word2Vec*. Aquest model, popular en processament de llenguatge natural, es reentrena aquí per aprendre representacions vectorials (*embeddings*) dels nodes basant-se en les seqüències generades pels *random walks*. Finalment,




Figure 2.4: Exemple de DeepWalk. Font: Medium

a l'apartat (d) els resultats es presenten en forma de matriu d'*embeddings*. Cada fila en aquesta matriu representa el vector d'*embeddings* d'un node, que encapsula la seva posició relativa i les relacions dins del graf. Aquests *embeddings* es poden utilitzar posteriorment per a tasques com la classificació de nodes, la predicció d'enllaços o la categorització de grafs.

De forma general es podria resumir en què primerament, l'algorisme *DeepWalk* genera un conjunt de *random walks* que comencen des de cada node del graf. Cada *random walk* és simplement una seqüència de nodes que comença en un node particular i es mou cap a un dels seus veïns en cada pas. Aquestes *random walks* capturen l'estructura local del graf i proporcionen una manera d'aprendre representacions dels nodes que reflecteixen les seves relacions amb els nodes propers.

A continuació, l'algorisme *Word2Vec* s'utilitza per aprendre representacions dels nodes basant-se en les caminades aleatòries generades. Tot i que el *Word2Vec* és un algorisme popular per aprendre representacions de paraules en el processament del llenguatge natural, també es pot aplicar per aprendre representacions dels nodes en un graf. La idea bàsica darrere de *Word2Vec*, de forma resumida, és aprendre una xarxa neuronal que prediu la probabilitat d'una paraula donat el seu context (és a dir, les paraules que apareixen abans i després d'ella).

2.2.4 GNN

Les xarxes neuronals gràfiques (GNN), o en anglès *Graph Neural Network*, són un tipus especial de xarxes neuronals dissenyades per treballar amb dades estructurades en forma de graf. Aquestes xarxes estan influenciades per les xarxes neuronals convolucionals (CNN), o en anglès *Convolutional Neural Network* i les tècniques d'incrustació de grafs, cosa que permet aplicar-les a la predicció de nodes, arestes i altres tasques basades en grafs. Les GNN són especialment útils en contextos en què les dades tenen una estructura complexa que no es pot tractar de manera efectiva amb xarxes neuronals convencionals.

Les xarxes neuronals de grafs són un enfocament innovador que ha tingut un gran impacte en l'aprenentatge automàtic aplicat a dades de grafs. Un dels primers articles que van introduir formalment el concepte de GNN, anomenat The graph neural network model, va ser publicat per Franco Scarselli i col·laboradors l'any 2009. Aquest treball va establir les bases per al desenvolupament de models d'aprenentatge profund capaços de processar dades no estructurades com els grafs.

De la mateixa manera que les CNN són utilitzades per a la classificació d'imatges, aplicant convolucions sobre una quadrícula de píxels per predir una classe, les GNN s'apliquen a l'estructura dels grafs per fer prediccions similars. Aquestes xarxes també s'assemblen a les xarxes neuronals recurrents, les quals s'utilitzen per a la classificació de textos, però en aquest cas, les GNN treballen amb estructures gràfiques on cada paraula pot ser vista com un node dins d'una frase. Això permet a les GNN tractar dades que no segueixen una estructura lineal o bidimensional, com és el cas dels grafs.

Les GNN es van introduir perquè les xarxes neuronals convolucionals no obtenien resultats òptims en situacions en què el graf tenia una grandària arbitrària i una estructura complexa. En lloc d'això, les GNN permeten la propagació d'informació entre nodes seguint les arestes del graf, capturant així les relacions i la topologia local del graf. Això els permet aprendre representacions vectorials que encapsulen informació rellevant sobre la posició i les relacions dels nodes dins del graf, la qual cosa és molt valuós en una àmplia varietat d'aplicacions, des de l'anàlisi de xarxes socials fins a la biologia computacional.

Hi ha diferents tipus de GNN modificats per cada necessitat, alguns dels més comuns són els següents:

- **Graph Convolutional Networks (GCNs):** Aquestes xarxes s'inspiren en les xarxes neuronals convolucionals (CNN) i són probablement les GNN més conegudes. Les GCN aprenen les característiques d'un node inspeccionant els seus nodes veïns i agregant la informació per passar-la a través de capes de la xarxa. Les GCN es divideixen en dos tipus principals: les xarxes convolucionals espacials, que defineixen convolucions basades en la topologia del graf, i les xarxes convolucionals espectrals, que utilitzen la descomposició espectral del Laplacà del graf per propagar la informació entre nodes.
- **Graph Attention Networks (GAT):** Aquestes xarxes utilitzen un mecanisme d'atenció per ponderar la importància dels nodes veïns en l'actualització de les representacions dels nodes. Això permet que les GAT se centrin més en les parts del graf que són més rellevants per a una tasca específica, millorant així l'eficàcia del model en problemes amb dependències complexes.
- **Message Passing Neural Networks (MPNN):** En aquestes xarxes, la informació es transmet com a "missatges" entre els nodes d'un graf. Cada node envia i rep missatges dels seus veïns, i després actualitza la seva representació en funció d'aquesta informació agregada. Les MPNN són molt flexibles i es poden adaptar a diferents tipus de problemes, però poden tenir problemes d'escalabilitat a causa de la necessitat de processar grans quantitats de missatges.
- **Graph Auto-Encoder Networks:** Aquestes xarxes utilitzen un enfocament d'*autoencoders* per aprendre representacions dels grafs. Un *encoder* aprèn a codificar la informació del graf en un espai latent, mentre que un *decoder* intenta reconstruir el graf original des d'aquest espai latent. Això és particularment útil per a tasques com la predicció d'enllaços, on és important capturar la relació entre nodes de manera efectiva.
- **GraphSAGE:** Aquesta tècnica és popular per al seu ús en grafs de gran escala. GraphSAGE utilitza un mètode de mostreig per seleccionar un subconjunt de veïns per a cada node en cada iteració, la qual cosa redueix els costos computacionals i permet treballar amb grafs molt grans.

Graph Convolutional Networks (GCN)

Les xarxes neuronals convolucionals de grafs (Graph Convolutional Networks, GCN) són un tipus específic de xarxes neuronals dissenyades per treballar directament amb dades de grafs. El concepte de GCNs va ser introduït formalment per Thomas Kipf i Max Welling en un article influent publicat l'any 2017, anomenat *Semi-supervised classification with graph convolutional networks*. Aquest treball va ser crucial per popularitzar l'ús de convolucions en grafs, cosa que permet l'aplicació de tècniques d'aprenentatge profund en xarxes complexes. Aquest tipus de xarxes neuronals són les que s'han utilitzat en aquest projecte.

Com les xarxes neuronals convolucionals (CNN) aquestes xarxes estenen el concepte de convolucions, utilitzades tradicionalment per a imatges, al domini dels grafs. En lloc de realitzar convolucions sobre una quadrícula regular de píxels, com es faria amb imatges, les GCN operen sobre la topologia d'un graf, que consisteix en nodes, que són les entitats i arestes que són les relacions entre aquestes.

El funcionament d'una GCN es basa en l'agregació de la informació dels nodes veïns per actualitzar la representació d'un node en particular, el que vol dir que cada node en el graf no només es representa per les seves pròpies característiques, sinó també per la informació dels seus veïns immediats. Aquest procés es repeteix en diverses capes, on cada capa de la GCN pot considerar informació de veïns més llunyans, capturant així totes les relacions dins del graf, tant les locals com les globals.

A més, les GCN utilitzen funcions d'activació no lineals, com la ReLU, després de cada pas d'agregació. Això introdueix no-linearitat en el model, i això permet que les GCN aprenguin representacions complexes dels nodes.

Per tant, les aplicacions de les GCN són àmplies i variades. Són especialment útils en casos on les dades tenen una estructura complexa, ja que, com s'ha explicat abans no es poden modelar de manera efectiva amb altres tipus de xarxes neuronals, com les CNN o les xarxes neuronals recurrents. Per exemple, en xarxes socials, les GCN poden ajudar a predir noves connexions entre usuaris, o en biologia computacional, poden ajudar a identificar funcions de proteïnes basades en la seva posició en una xarxa de proteïnes, utilitzant les representacions complexes dels nodes. Aquesta capacitat de modelar la complexitat inherent als grafs fa que les GCN siguin molt útils en el *machine learning*.




Figure 2.5: Representació d'una GCN. Font: tkipf.github

A la figura 2.5 es pot observar el funcionament d'una *Graph Convolutional Network* (GCN), mostrant el procés de propagació d'informació a través de les capes de la xarxa. La imatge representa el flux de dades a través d'una GCN, mostrant com la informació dels nodes es combina i processa per capturar les relacions estructurals del graf, cosa que permet així a la xarxa fer prediccions o aprendre noves característiques sobre el graf.

Primerament, a l'esquerra es veu la representació inicial d'un graf com a *input*, és a dir, com a entrada on els nodes estan connectats per arestes. L'entrada de la xarxa conté la informació bàsica dels nodes i les seves connexions.

A continuació, hi ha un apartat anomenat *hidden layers*, el que en català vol dir capes ocultes. Se'n poden observar dues, cadascuna representant una etapa de processament dins de la GCN. En cada capa oculta, la informació dels nodes s'actualitza en funció de la informació dels seus veïns, agregant dades que reflecteixen les relacions locals dins del graf. Aquest procés permet a la xarxa capturar patrons i dependències complexes. Després de cada capa oculta, la informació processada passa a través d'una funció d'activació ReLU (*Rectified Linear Unit*), que introdueix no linearitat en el model. Això ajuda la xarxa a aprendre representacions més riques i complexes dels nodes.

Finalment, a la dreta, es veu l'*output*, o en català, la sortida de la xarxa, que és una nova representació del graf, amb la informació actualitzada després de passar per les capes ocultes i les funcions d'activació. Aquesta representació final es pot utilitzar per a diverses tasques, com la classificació de nodes, la predicció d'enllaços, o la categorització del graf complet.

GraphSAGE

Un altre concepte a recalcar és el *GraphSAGE*, el que vol dir *Graph Sample and Aggregate*, i és un algorisme avançat, escalable i versàtil dissenyat per a l'aprenentatge automàtic en grafs. A diferència dels mètodes tradicionals que generen una representació única per a cada node del graf, *GraphSAGE* es focalitza en l'aprenentatge d'una funció d'agregació generalitzada que es pot aplicar tant als nodes existents com als nodes no vistos durant l'entrenament. Això permet generar *embeddings* de nodes que són capaços de capturar la informació estructural i les característiques locals del graf, proporcionant una representació compacta i útil per a diverses tasques.

El *GraphSAGE* és un algorisme innovador per a l'aprenentatge de representacions de nodes en grafs, introduït per Will Hamilton, Rex Ying i Jure Leskovec l'any 2017 en un article anomenat *Advances in Neural Information Processing System*. A diferència dels mètodes tradicionals que aprenen *embeddings* per a un graf complet, *GraphSAGE* aprèn una funció d'agregació que es pot aplicar a grafs nous, fent-lo més escalable i adaptable a grans xarxes.

El funcionament de *GraphSAGE* es basa en dues etapes principals: el mostreig i l'agregació. En primer lloc, per a cada node, se selecciona un subconjunt de veïns mitjançant un procés de mostreig aleatori, la qual cosa permet escalar l'algorisme per treballar amb grafs molt grans. A continuació, *GraphSAGE* aplica una funció d'agregació sobre les representacions dels veïns seleccionats, combinant aquesta informació per actualitzar la representació del node d'interès. Aquest procés es pot repetir a través de diverses capes per

capturar informació de veïns més llunyans en el graf.

Una de les característiques més destacades de *GRAPHSAGE* és la seva capacitat per generalitzar a nodes nous que no estaven presents durant l'entrenament, una propietat coneguda com a aprenentatge inductiu. Això és especialment útil en aplicacions on els grafs canvien amb el temps, com en xarxes socials, sistemes de recomanació o grafs d'informació dinàmics. Aquesta capacitat d'aprenentatge inductiu, combinada amb la flexibilitat per utilitzar diferents tècniques d'agregació, fa de GraphSAGE una eina poderosa per a l'anàlisi de grafs.




Figure 2.6: Exemple de GraphSAGE. Font: ResearchGate

A la figura 2.6, es pot observar un exemple del procés de *GraphSAGE*. Primerament, a la part anomenada *Product relationship network*, a l'esquerra, es mostra un graf que representa les relacions entre diferents productes. Els nodes representen els productes, i les arestes representen les relacions entre aquests productes.

A continuació, hi ha *Sample Neighborhood of a Central Node*, el que en català vol dir Mostreig del Veïnat d'un Node Central. La part central de la imatge mostra com *GraphSAGE* selecciona un conjunt de veïns d'un node central (en aquest cas, un cotxe). Aquest procés de mostreig es realitza en diferents "capes" o nivells ($K=1$, $K=2$), on es consideren els veïns immediats ($K=1$) i els veïns dels veïns ($K=2$).

Finalment a *Aggregate Feature Information from Neighbors*, o en català, Agregació de la Informació de les Característiques dels Veïns, mostra com s'agreguen les característiques dels veïns per generar la representació del node central. Aquí es veu com les característiques dels veïns es processen a través d'agregadors, que poden ser funcions com la mitjana, una xarxa neuronal, o altres mètodes d'agregació, per combinar la informació i actualitzar la representació del node central.

Diferències entre els GCN i el GraphSAGE

La diferència més gran entre el *GraphSAGE* i els GCN, prèviament explicats, és que tot i que ambdós algorismes són utilitzats per generar representacions de nodes en grafs en *GraphSAGE*, es fa un mostreig aleatori dels veïns dels nodes per a cada nivell (com es veu en l'esquema central). Això permet escalar l'algorisme a grafs molt grans, ja que només es consideren una quantitat limitada de veïns. I, en canvi, les GCN normalment consideren tots els veïns d'un node per a l'agregació. Això pot ser ineficient en grafs molt densos o grans, perquè el nombre de veïns pot ser molt elevat.

Altres diferències entre els dos és que el *GraphSAGE* utilitza funcions d'agregació

explícites que es poden ajustar, com la mitjana, la màxima, o combinacions amb xarxes neuronals. Això fa que sigui més flexible i adaptatiu a diferents tipus de grafs. I els GCN utilitzen una operació de convolució sobre el graf que és més rígida i que pot ser menys personalitzable que l'agregació de *GraphSAGE*. La convolució en GCN és una combinació lineal de les característiques dels nodes veïns, seguida d'una no-linealitat. A més el *GraphSAGE* té un aprenentatge més inductiu mentre que els GCN aprenen de manera transductiva, és a dir, aprenen representacions per a nodes específics del graf d'entrenament i no generalitzen fàcilment a nodes nous.

En resum, *GraphSAGE* és més escalable i flexible gràcies a la seva capacitat de mostreig i agregació de veïns, així com la seva habilitat per generalitzar a nodes nous. Els GCN són més directes i utilitzen la convolució del graf per a la propagació de característiques, però pot ser menys eficient en grafs grans i menys adaptable a noves dades.

Chapter 3

Dades

Les dades proporcionades han estat obtingudes de l'Hospital Clínic de Barcelona i Nàpols, Itàlia. Aquest estudi ha utilitzat dades extretes de pacients diagnosticats amb EM segons els criteris de McDonald 2017 (Thompson, et al.2018) i controls sans de les bases de dades radiològiques i clíniques del Centre d'EM de la Universitat de Nàpols "*Federico II*". El projecte es va dur a terme d'acord amb la Declaració de Helsinki, amb el consentiment informat escrit obtingut de cada participant. Aquestes proves han estat fetes tant en homes com en dones de diferents edats.

3.1 Cohort i MRI

En aquest apartat, es descriu la composició de la cohort utilitzada en l'estudi, així com les dades generals dels pacients i els controls.

L'estudi va incloure un total de 270 participants, dividits en dos grups: pacients i controls. D'aquests participants 165 eren de les dades de l'Hospital Clínic, dels quals 147 eren pacients i 18 controls. Aquest biaix tan gran va ser el motiu pel qual després es van afegir les dades provinents de Nàpols, els quals eren 105 participants i per poder arreglar el biaix tots eren controls. Amb els dos grups de dades conjunts de pacients, que tenen edats de des de setze anys fins a setanta, es van acabar tenint 147 pacients i 123 controls.

Les dades es van recollir utilitzant la tècnica de ressonància magnètica (MRI), per obtenir informació detallada sobre les estructures cerebrals durant els anys 2016 i 2017. Per extreure les matrius en l'anàlisi multicapa de dades morfològiques, es comencen creant matrius d'adjacència que representen diferents tipus de connexions o relacions entre nodes en cadascuna de les capes. Aquestes matrius es processen posteriorment per alinear-les i capturar l'estructura multicapa, que permet analitzar la complexitat de les interaccions morfològiques a diversos nivells.

Les dades de l'Hospital Clínic de Barcelona estaven dividides en tres carpetes, anomenades FA, GM i RS, essent en ordre l'anisotropia fraccional, la substància grisa i l'estat de repòs. En cada carpeta hi ha un total de 165 matrius d'adjacència, corresponent al nombre de pacients que s'han estudiat. Aquestes matrius d'adjacència són de 76x76, que és el nombre de regions del cervell que s'estudien, amb valors en el rang $[0,1]$, on els valors baixos indiquen per a FA una connectivitat dolenta, mentre que per a GM i RS indiquen una correlació dolenta, en el primer en la forma i en el segon en l'activació simultània de dues regions cerebrals. Els valors propers a 1 indiquen el contrari, és a dir bona connectivitat i

correlació. També hi ha un document el qual conté una ID que correspon als 165 pacients i la columna important és la de *mstype*, que és amb la que es treballa durant gran part. Aquesta columna conté números del -1 al 3, on -1 és un pacient control (és a dir, no malalt), i del 0 al 3 són pacients malalts però amb diferent *subtipus*. Per últim, hi ha un altre arxiu, el qual conté dues columnes: ID i nom de les 76 regions del cervell que s'estudien.

Les dades provinents de Nàpols contenen també les tres carpetes FA, en aquest cas anomenada *DTI_networks*, GM que aquí es diu *GM_networks* i RS, aquí anomenada *rsfmri_networks*. En aquest cas hi ha un total de 105 matrius d'adjacència corresponents als 105 pacients que hi ha, de nou de 76x76 i amb valors en el rang [0,1]. Hi ha quatre arxius a més; el primer conté dades relacionades amb les mètriques de difusió de la substància grisa dels subjectes, el segon conté dades relacionades amb la fracció d'anisotropia de la substància grisa dels subjectes, el tercer conté dades dels pacients, com l'edat i el sexe i l'últim conté informació sobre els nodes utilitzats en les anàlisis de grafs com ara noms de regions cerebrals.

D'aquestes dades es van acabar barrejant ambdós FA, GM i RS en un sol per fer més fàcil el treball. El mateix es va fer amb l'arxiu que contenia si eren pacients o control al qual se li van afegir les columnes de més i es van classificar els pacients nous de Nàpols tots com a control.

3.2 Processament de les dades

3.2.1 Creació dels grafs

Primerament, s'han carregat tots els arxius de les carpetes, tant de l'Hospital Clínic com de Nàpols i s'han ajuntat com s'ha explicat prèviament. Un cop fet l'agrupament corresponent, hi ha les dades de FA, GM i RS conjuntes i l'arxiu que conté si són pacients o controls d'ambdós llocs.

A continuació, s'ha fet una anàlisi descriptiva que s'explicarà a la secció 4.1, una de les seccions a l'anàlisi descriptiva ha estat fer histogrames de l'anisotropia fraccional, la substància grisa i l'estat de repòs d'on s'han extret uns *thresholds*, és a dir, uns llindars per poder eliminar arestes per a cada graf. Posteriorment, s'han creat els 270 grafs per a cada secció, cadascun de 76 nodes.

3.2.2 NetworkX

Per fer aquests grafs s'ha utilitzat la llibreria NetworkX, la qual és una llibreria de Python àmpliament utilitzada per crear, manipular i analitzar grafs o xarxes complexes. NetworkX ofereix una plataforma flexible per a la construcció i anàlisi de grafs, cosa que la converteix en una eina essencial per a qualsevol que treballi amb dades relacionals.

Una de les característiques principals de NetworkX és la seva capacitat per crear diversos tipus de grafs, incloent-hi grafs no dirigits, dirigits, ponderats, bipartits i multi-grafs, que són grafs amb múltiples arestes entre els mateixos parells de nodes. A més, NetworkX permet afegir atributs addicionals als nodes i arestes, com pesos, etiquetes o colors, cosa que permet un modelatge molt detallat i adaptat a les necessitats específiques de l'usuari.

Pel que fa a la manipulació de grafs, NetworkX proporciona funcions per afegir, eliminar i modificar nodes i arestes de manera senzilla i eficient. També permet l'extracció de

subgrafs basats en criteris específics, facilitant l'anàlisi de parts específiques de la xarxa. Aquesta capacitat de manipulació és clau per a la construcció de grafs complexos i per adaptar-los a les necessitats d'anàlisi.

NetworkX també és molt potent en l'anàlisi de grafs, oferint una àmplia gamma d'algorismes i mesures estructurals. Per exemple, es poden calcular mesures de centralitat, com *PageRank* o *betweenness*, així com la clústerització, la distància més curta entre nodes i el diàmetre del graf. Aquestes mesures s'han utilitzat per aconseguir dades sobre el graf i s'han aplicat els algorismes.

Finalment, *NetworkX* és compatible amb altres llibreries i formats de dades, com *Pandas* per treballar amb *DataFrames* o formats de fitxers com *GraphML* i GML per importar i exportar grafs. Aquesta compatibilitat la fa molt útil per integrar-se en fluxos de treball més amplis en ciència de dades o investigació.

Chapter 4

Metodologia

L'objectiu d'aquest treball ha estat aplicar diferents formes d'anàlisi i models per poder observar si els resultats que s'obtenien de classificar els voluntaris en pacients o control eren bons i si milloraven.

Primerament, s'ha fet una anàlisi visual, per veure la forma de les dades i si pot aportar alguna informació important com per exemple on fer el *threshold* en crear els grafs. Un cop s'han creat els grafs s'han extret les mètriques dels nodes i dels grafs, les mètriques dels nodes han estat *degree*, *strength*, *closeness centrality*, *betweenness centrality* i *eigenvector centrality*, les mètriques que s'han extret dels grafs han estat *average degree*, *average clustering* i *density*. Aquestes mètriques s'han guardat en diferents documents.

Els primers models que s'han generat han estat aplicant aquestes mètriques, tant les dels nodes com les dels grafs, a màquines de vectors de suport i a regressions logístiques.

Posteriorment, s'ha fet el mateix però aquest cas amb *embeddings* creats mitjançant *Word2Vec* i *Node2Vec*. També s'ha utilitzat l'SVM i la regressió logística. A més, s'han guardat els *embeddings* en documents per poder-los utilitzar per separat.

Finalment, s'ha utilitzat una *Graph Convolutional Network* (GCN), i mitjançant el test AUC s'han analitzat els documents de totes les mètriques dels nodes i dels grafs, i els documents dels *embeddings*.

En resum, mitjançant les matrius d'adjacència de les dades que es tenien, que eren en total 270 per a FA, GM i RS s'han creat els grafs els quals s'han ajuntat per generar un conjunt d'entrenament i test, posteriorment aquest conjunt format per 147 pacients d'EM i 123 controls, ha passat a ser 200 participants en l'entrenament i 70 a test per poder passar per diferents models supervisats.

4.1 Mètodes d'anàlisi

Per començar, s'ha produït la separació mitjançant el *mstype*, el qual catalogava si eren controls o bé pacients en diferents subtipus, classificant com a diferents variables els controls i els pacients i s'han produït diferents formes de poder observar les dades de forma més gràfica i comparativa entre elles com ara matrius o mapes de calor de diferències de connectivitat funcional cerebral entre dos grups: "Control" i "Pacient". Totes les diferents

matrius de connectivitat que s'estudien estan tallades per la meitat, ja que les matrius són simètriques.

4.1.1 Representació gràfica de les dades i anàlisi descriptiva

Matrius de diferències de connectivitat funcional cerebral entre els controls i els pacients

La figura 4.1 mostra tres matrius de diferències de connectivitat funcional cerebral entre dos grups: "Control" i "Pacient". Aquestes matrius representen les diferències en connectivitat cerebral entre controls sans i persones amb esclerosi múltiple (EM), representades com a matrius de diferències per a diverses mesures com FA (Anisotropia Fraccional), GM (Substància grisa) i RS (connectivitat funcional en estat de repòs). Els eixos representen diferents regions cerebrals i cada cel·la de la matriu indica la diferència de connectivitat entre dues regions. Si el color de la cel·la tendeix més a blau indica una reducció de connectivitat en els pacients comparat amb el grup de control i, en canvi, si el color de la cel·la tendeix més a vermell és al contrari. Aquest tipus d'anàlisi ajuda a identificar com l'esclerosi múltiple pot afectar la connectivitat del cervell en comparació amb persones sanes.

En la matriu de diferències de FA (Anisotropia Fraccional), es pot observar una disminució en diverses connexions, suggerint una pèrdua de la integritat de la matèria blanca en els pacients. Això és coherent amb els danys associats amb l'esclerosi múltiple, on la desmielinització és una característica predominant. Els pocs increments en FA podrien indicar regions on hi ha una compensació o canvis estructurals adaptatius, suggerint que certes àrees del cervell poden estar intentant adaptar-se als danys estructurals.

Pel que fa a GM (Substància grisa), les regions amb disminució de substància grisa podrien correspondre a atrofia o pèrdua de volum de substància grisa, un fenomen que sovint s'observa en pacients amb EM. La reducció de la substància grisa està associada amb el deteriorament cognitiu i altres símptomes clínics de l'EM, com ara problemes de memòria i funció executiva. Això reflecteix l'impacte que l'esclerosi múltiple té en les àrees del cervell implicades en funcions cognitives crítiques.

En la matriu de RS (connectivitat funcional en estat de repòs), la reducció de connectivitat funcional observada en els pacients pot reflectir una desconexió funcional entre regions cerebrals, cosa que podria estar relacionada amb la simptomatologia clínica de l'esclerosi múltiple, com la fatiga o la dificultat cognitiva. Les zones amb un augment de connectivitat podrien indicar, de nou, mecanismes de compensació o reorganització funcional, on certes àrees del cervell intenten adaptar-se als dèficits funcionals.

Com a conclusió general, els gràfics de diferències mostren canvis significatius en la connectivitat cerebral entre controls i pacients amb esclerosi múltiple. Aquests resultats suggereixen que la malaltia afecta tant la connectivitat estructural com funcional, amb una disminució generalitzada en la integritat de les fibres de substància blanca, atrofia de substància grisa, i alteracions en la connectivitat funcional. Aquestes troballes són coherents amb el coneixement actual sobre com l'esclerosi múltiple impacta el cervell, oferint una visió més detallada dels canvis neurològics associats amb la malaltia.

Estudi de la connectivitat

En la figura 4.2, es poden observar tres matrius de connectivitat generals, els eixos representen diferents regions cerebrals (nodes) dins d'una xarxa de connectivitat cerebral. Cada cel·la de la matriu indica la força de la connectivitat dels diferents tipus (FA, GM i RS) entre dues regions específiques del cervell. Les cel·les que tenen un color més groguenc indiquen un valor alt i, per tant, suggereix una alta integritat de la connectivitat entre els nodes, d'altra banda, les cel·les que tenen un color més porpra indiquen un valor més baix i, per tant, una integritat més baixa. Els colors verd i turquesa són més intermedis.

En la matriu de FA (Anisotropia Fraccional), es poden observar diverses connexions amb valors de connectivitat elevats, indicats per colors groguencs. Això suggereix una alta integritat de les fibres de matèria blanca entre aquestes regions cerebrals. Tanmateix, també hi ha zones amb valors més baixos, representades en colors verdosos o porpra, que podrien indicar una disminució en la integritat de la matèria blanca. Aquesta variabilitat en la connectivitat de FA pot estar relacionada amb les diferències individuals en la integritat estructural de la matèria blanca.

La matriu de GM (Substància grisa), presenta una distribució més homogènia de valors de connectivitat, predominantment en tons groguencs, el que indica una alta integritat i una estructura cerebral relativament estable en aquestes regions. No obstant això, hi ha algunes cel·les amb colors més foscos, el que suggereix possibles àrees amb menor densitat o volum de substància grisa. Aquestes diferències poden estar associades amb processos neurodegeneratius o amb variacions individuals en la composició de la substància grisa generats per l'esclerosi múltiple.

En la matriu de RS (connectivitat funcional en estat de repòs), s'observa una certa variabilitat en els patrons de connectivitat entre diferents regions del cervell. Les zones amb colors groguencs indiquen una connectivitat funcional forta, mentre que les regions amb colors més foscos, com el porpra, podrien reflectir una desconexió funcional o una menor interacció entre aquestes àrees en estat de repòs. Aquesta variabilitat en la connectivitat RS pot estar relacionada amb la capacitat del cervell per mantenir comunicació funcional entre regions clau, fins i tot quan no s'està duent a terme cap tasca específica tot i que es pateixi la malaltia.

Com a conclusió general d'aquestes matrius de connectivitat, es pot observar que la connectivitat cerebral varia entre les diferents regions i tipus de dades analitzades (FA, GM i RS). Les regions amb alta integritat estructural o funcional són evidents, així com les àrees amb menor connectivitat que podrien estar associades amb alteracions o deficiències neurològiques generades per l'esclerosi múltiple.

Histogrames

En la figura 4.3 es mostren els histogrames dels valors generals obtinguts en les dades de FA (Anisotropia Fraccional), GM (Substància grisa) i RS (connectivitat funcional en estat de repòs). Aquests histogrames s'han utilitzat per establir un llindar (*threshold*) amb l'objectiu de filtrar i eliminar les arestes menys significatives en els grafs de connectivitat cerebral. Aquest *threshold* s'ha escollit amb la funció `calculate_threshold`, i s'ha comprovat mitjançant els histogrames si tenia sentit.

L'histograma de FA (Anisotropia Fraccional), mostra una distribució de valors amb una gran concentració prop de zero, indicant que moltes de les connexions tenen un valor d'anisotropia fraccional molt baix. Aquest pic a zero pot suggerir la presència de connexions que no són rellevants o que tenen poca integritat estructural. A mesura que els valors augmenten, la freqüència disminueix, creant una distribució asimètrica amb una cua a la dreta. Aquesta informació s'ha utilitzat per determinar un llindar que permeti eliminar les arestes amb valors baixos, preservant així les connexions més fortes i potencialment més significatives en el graf. La funció `calculate_threshold` ha situat el llindar dels grafs entre 0.3 i 0.4, el qual es correlaciona completament amb el pic que hi ha a l'histograma.

L'histograma de GM (Substància grisa), presenta una distribució bimodal amb dos pics, un a prop de zero i un altre al voltant de 0.6. Aquestes dades suggereixen que hi ha dues poblacions de valors: una amb densitats de substància grisa molt baixes, que poden correspondre a connexions menys importants o soroll, i una altra amb valors més alts, que probablement representen connexions significatives. A partir d'aquesta distribució, s'ha establert un llindar per a GM que permet filtrar les connexions amb valors baixos, assegurant que només es mantinguin les connexions més rellevants en l'anàlisi dels grafs. La funció `calculate_threshold` ha situat el llindar dels grafs entre 0.6 i 0.7, el qual es correlaciona completament amb el pic que hi ha a l'histograma.

En l'histograma de RS (connectivitat funcional en estat de repòs), s'observa una distribució més simètrica amb un pic al voltant de 0, però que inclou una gamma de valors negatius i positius. La major part dels valors estan en el rang positiu baix, però també hi ha presència de valors en els extrems negatius i positius, indicant variabilitat en la connectivitat funcional en estat de repòs. Aquest patró ha estat utilitzat per determinar un llindar que elimina les connexions més dèbils o inestables, centrant-se en les connexions que tenen un paper més significatiu en la xarxa funcional cerebral. A diferència de la resta d'histogrames aquest no és entre 0 i 1, sinó entre -1 i 1. De nou s'ha utilitzat la funció `calculate_threshold` tot i que en aquest cas és on més ha variat el graf escollit, tot i això, la majoria han estat al voltant del 0.4, de forma sorprenent, ja que el pic està una mica abans. Això probablement és degut al fet que el rang de x és més gran que en els altres dos casos.

Aquests histogrames han estat crucials per establir llindars que permetin filtrar les arestes dels grafs de connectivitat cerebral, eliminant les connexions menys rellevants i mantenint aquelles que podrien ser més significatives en l'anàlisi. Això ajuda a simplificar i clarificar la xarxa, centrant l'atenció en les connexions que tenen un impacte més gran en la interpretació de les dades i en la comprensió de les alteracions neurològiques. Gràcies a aquests histogrames s'han pogut reduir el nombre d'arestes de cada graf de 2800 a un llindar de des de 400 fins a 700.

4.1.2 Mètriques dels grafs

Un cop creats els diferents grafs utilitzant la llibreria NetworkX, es poden contar 270 grafs (un per cada persona) cadascun de 76 nodes (regions del cervell), de cadascun dels tres tipus (FA, GM i RS). D'aquests grafs i nodes s'extreuen diferents mètriques per poder-les utilitzar en diferents models, de nou amb l'ajut de la llibreria NetworkX. Aquestes mètriques s'han guardat a diferents documents per poder-los importar amb més facilitat.

Dels nodes:

- **Degree (Grau):** El grau d'un node és el nombre de connexions o arestes que té amb altres nodes. En el context d'una xarxa cerebral, indica quantes altres regions cerebrals estan connectades amb una determinada regió. Serveix per identificar nodes importants que poden actuar com a centres de comunicació o punts de connexió en la xarxa. Un grau alt indica una alta interconnexió.
- **Strength (Força):** La força d'un node és la suma dels pesos de les arestes connectades a aquest node. La força mesura la intensitat total de les connexions d'un node, per tant, permet identificar quins nodes tenen una connectivitat més forta, la qual cosa pot indicar regions cerebrals amb una alta activitat o influència.
- **Eigenvector Centrality (Centralitat de Vector Propi):** Mesura la influència d'un node en una xarxa, valorant no només el nombre de connexions sinó també la importància dels nodes connectats. És útil per identificar nodes crítics o regions clau en xarxes on es poden destacar regions amb gran influència per la seva connexió amb altres regions influents.
- **Betweenness Centrality (Centralitat d'Intermediació):** Mesura quan un node actua com a pont o intermediari en el camí més curt entre altres dos nodes de la xarxa. Un node amb alta centralitat d'intermediació participa en molts dels camins més curts entre parelles de nodes. Identifica nodes que són crítics per a la comunicació o el flux d'informació en una xarxa. En xarxes cerebrals, pot ajudar a trobar regions clau per a la transmissió de senyals, on la seva disfunció podria interrompre la comunicació entre diverses parts del cervell.
- **Closeness Centrality (Centralitat de Proximitat):** Mesura com de prop està un node de tots els altres nodes de la xarxa, basant-se en la distància mitjana dels camins més curts. Un node amb alta centralitat de proximitat pot arribar a altres nodes amb menys passos. Ajuda a identificar nodes que poden accedir ràpidament a tota la resta de la xarxa. En el context del cervell, una alta centralitat de proximitat pot indicar regions que poden influir ràpidament sobre altres regions.

Dels grafs:

- **Average Degree (Grau Mitjà):** És la mitjana del nombre de connexions per node en la xarxa. Es calcula sumant els graus de tots els nodes i dividint pel nombre total de nodes. Indica el nivell general de connectivitat en la xarxa. Un grau mitjà alt suggereix que, de mitjana, cada regió cerebral està connectada amb moltes altres.
- **Average Clustering (Clúster Mitjà):** Mesura el grau en què els nodes d'una xarxa tendeixen a agrupar-se. Es calcula com la mitjana dels coeficients de *clustering* de tots els nodes, on el coeficient de *clustering* d'un node és la proporció de connexions existents entre els seus veïns comparat amb el nombre màxim possible de connexions entre aquests. Permet identificar la presència de subgrups o comunitats dins la xarxa. Un alt coeficient de *clustering* indica que els nodes tendeixen a formar clústers densos, la qual cosa pot ser important en l'organització funcional del cervell.
- **Density (Densitat):** És la proporció del nombre real de connexions en la xarxa respecte al nombre màxim possible de connexions. Es calcula com el nombre total d'arestes dividit pel nombre màxim possible d'arestes. Mesura la cohesió global de la xarxa. Una alta densitat indica que una gran proporció de nodes estan connectats entre si, cosa que pot reflectir una comunicació eficient dins de la xarxa.

4.2 Tècniques de preprocessament

4.2.1 Feature Scaling

StandardScaler

Les característiques numèriques han estat normalitzades utilitzant *StandardScaler* per garantir que totes tinguessin la mateixa escala, fet que millora el rendiment dels models.

El *StandardScaler* és una eina disponible a la llibreria *scikit-learn* de Python que s'utilitza per estandarditzar les característiques d'un conjunt de dades. Estandarditzar significa redimensionar les dades perquè tinguin una mitjana de 0 i una desviació estàndard d'1. Això es fa per assegurar que cada característica tingui la mateixa escala, cosa que pot millorar el rendiment de molts algorismes d'aprenentatge automàtic que són sensibles a la magnitud de les característiques.

El *StandardScaler* es basa en la següent fórmula per transformar cada característica X_i :

$$X'_i = \frac{X_i - \text{mean}(X_i)}{\text{std}(X_i)}$$

On:

- X_i és el valor original de la característica.
- $\text{mean}(X_i)$ és la mitjana dels valors de la característica X_i .
- $\text{std}(X_i)$ és la desviació estàndard dels valors de la característica X_i .

Després d'aplicar el *StandardScaler*, els valors transformats tindran una distribució amb mitjana 0 i desviació estàndard 1, el que és molt útil per aplicar models com la SVM o la regressió logística.

K-Fold Cross-Validation

Inicialment, abans d'obtenir les dades provinents de Nàpols, hi havia un gran desbalanceig en pacients i controls, ja que hi havia molts pacients, i molt pocs controls. Per aquest motiu s'havia fet *K-Fold Cross-Validation*, la qual és una tècnica de validació utilitzada en l'aprenentatge automàtic per avaluar el rendiment d'un model de manera més robusta.

El *K-Fold Cross-Validation* consisteix a dividir el conjunt de dades en K subconjunts o *folds*. El model s'entrena K vegades, cada vegada utilitzant un dels *folds* com a conjunt de validació i els altres K-1 *folds* com a conjunt d'entrenament. Al final, es calcula la mitjana de les mètriques de rendiment obtingudes en cadascuna de les K iteracions, proporcionant una estimació més fiable de la capacitat predictiva del model. Aquesta tècnica ajuda a evitar el sobre ajustament i aprofita millor les dades disponibles. Un cop es van afegir les dades provinents de Nàpols ja no va ser necessari perquè no hi havia desbalanceig.

SMOTE

També es va haver d'aplicar, tot i que un cop rebudes les dades de Nàpols es va treure, l'SMOTE.

L'SMOTE, que en anglès són les sigles de *Synthetic Minority Over-sampling Technique*, és una tècnica utilitzada en l'aprenentatge automàtic per tractar el problema de classes desbalancejades. Quan una classe està *subrepresentada* en un conjunt de dades, SMOTE genera noves instàncies sintètiques d'aquesta classe minoritària mitjançant la interpolació entre exemples existents. Això ajuda a equilibrar les classes, millorant el rendiment dels models en predir la classe minoritària i reduint el biaix cap a la classe majoritària.

4.2.2 Shuffle

L'última tècnica de preprocessament que s'ha utilitzat abans d'entrenar els models ha estat la comanda `shuffle`. Aquesta comanda ha estat necessària perquè les dades de Nàpols, on tots els voluntaris eren controls, estaven situades a continuació de les dades provinents de l'Hospital Clínic. Si no es barrejaven, aquesta organització podria haver induït biaixos en els models, fent-los menys generalitzables i més susceptibles a sobre ajustar-se als patrons específics de les dades de control.

Amb l'ús de *shuffle*, s'ha aconseguit barrejar de manera aleatòria els elements d'una llista o conjunt de dades, alterant l'ordre original dels elements. Això proporciona una seqüència nova que és una permutació aleatòria de l'original, barrejant les dades abans de dividir-les en entrenament i prova. D'aquesta manera, es garanteix una distribució més homogènia i representativa de les dades durant l'entrenament, minimitzant el risc de biaixos i millorant el rendiment del model.

Aquesta barreja és especialment important per assegurar que el model no aprengui patrons espuris associats a la ubicació original de les dades, sinó que es concentri en les característiques rellevants per a la tasca de classificació.

4.3 Entrenament dels Models amb els Documents

Un cop ja estava tot preparat, amb els conjunts de dades desbiaixats i les dades barrejades correctament, s'ha fet l'entrenament dels models.

Els models s'han entrenat amb les dades d'entrada i cada mètrica dels nodes i grafs per separat mitjançant el seu document corresponent dels que s'havien creat anteriorment, la y sempre ha estat el mateix, que és l'*mstype* que és segons el que volem classificar (si són pacients o controls).

S'ha aplicat el `train_test_split` de *Scikit-learn* per dividir les dades correctament en els dos subgrups: un conjunt d'entrenament i un conjunt de test, el primer consta de 200 participants i el segon de 70. Aquest procés és fonamental en l'entrenament de models d'aprenentatge automàtic, ja que permet avaluar el rendiment del model en dades que no s'han utilitzat per entrenar-lo, proporcionant així una indicació de com generalitzarà el model a dades noves. S'han destinat el 80% de les dades al conjunt d'entrenament i el 20% restant al de prova. També s'ha aplicat `random_state=42` per garantir que cada cop que s'executi el codi hi hagi reproductibilitat dels resultats, és a dir, que sempre siguin els mateixos.

SVM

L'SVM (Support Vector Machine) és un algorisme d'aprenentatge automàtic utilitzat principalment per a tasques de classificació. El seu objectiu és trobar un hiperplà òptim que separi les dades en dues classes diferents, maximitzant la distància (marge) entre les dades més properes de cada classe i l'hiperplà. SVM pot treballar en espais lineals i no lineals, utilitzant "nuclis" per transformar les dades i fer-les separables. És conegut per la seva efectivitat en conjunts de dades d'alta dimensionalitat i per ser robust contra el sobreajustament.

Logistic Regression

La regressió logística és un mètode d'aprenentatge automàtic utilitzat per a la classificació binària. Modela la probabilitat que una observació pertanyi a una de les dues classes possibles, utilitzant una funció sigmoide que transforma els valors d'entrada en una probabilitat entre 0 i 1. A partir d'un llinard (per exemple, 0,5), es decideix a quina classe pertany l'observació. Tot i el seu nom, és un mètode de classificació, no de regressió, i és especialment útil per predir esdeveniments binaris com sí/no, veritat/fals, o present/absent.

4.4 Creació i entrenament d'embeddings

Posteriorment, s'ha dut a terme l'anàlisi mitjançant, de nou, una SVM i la regressió logística, però, en aquest cas amb *embeddings*. Mitjançant *RandomWalk* i *DeepWalk*, s'ha creat un model *Word2Vec* i un altre *Node2Vec* per generar embeddings d'individus, que són els que després passen pels models supervisats. Aquests embeddings, tant el de *Word2Vec* com el *Node2Vec*, s'han exportat com a documents, també, per poder facilitar el seu accés.


Aquests *embeddings* a més de poder observar el *Classification Report* com amb els models anteriors, han ajudat a observar quins nodes tenen similituds amb altres dels 76 nodes de les regions cerebrals, i s'han representat com es pot veure a la figura 4.4.

4.5 GCN


Finalment, s'ha creat una *Graph Convolutional Network* amb tres *folds*, el que vol dir que el conjunt de dades s'ha dividit en tres parts per realitzar la validació creuada. Això implica que en cada iteració del procés, el model s'entrena amb dues de les tres parts del conjunt de dades i es valida amb la part restant. Aquest procés es repeteix tres vegades, canviant el *fold* utilitzat per a la validació en cada iteració, de manera que cada part s'utilitza tant per a entrenar com per a validar el model. Aquest enfocament permet avaluar el rendiment del model de manera més consistent, reduint la possibilitat que els resultats estiguin esbiaixats per una partició específica del conjunt de dades i millorant així la capacitat del model per generalitzar a noves dades.

Se li han introduït els documents que contenen les mètriques dels nodes i dels grafs de FA, GM i RS, i els *embeddings* de *Word2Vec* i de *Node2Vec* de FA, GM i RS, i la GCN li ha aplicat el test AUC a cadascuna de les dades.


El test AUC utilitza l'AUC (*Area Under the Curve*) la qual és una mètrica que mesura el rendiment d'un model de classificació calculant l'àrea sota la corba ROC (Receiver Operating Characteristic). Aquesta corba mostra la relació entre la taxa de falsos positius i la taxa de certs positius a diferents llindars de decisió. Un AUC d'1 indica una classificació perfecta, mentre que un AUC de 0.5 suggereix que el model no distingeix millor que l'atzar. L'AUC és especialment útil en situacions de desequilibri de classes, ja que ofereix una visió global de la capacitat del model per separar les classes positives i negatives.



(a) FA




(b) GM




(c) RS


Figure 4.1: Diferències de connectivitat control-pacient



(a) FA




(b) GM




(c) RS


Figure 4.2: Matrius de connectivitat



(a) FA




(b) GM




(c) RS


Figure 4.3: Histogrames



(a) FA



(b) GM



(c) RS

Figure 4.4: Representacions dels embeddings

Chapter 5

Resultats

En aquest capítol s'explicaran els resultats obtinguts de tots els diferents mètodes que s'han plantejat al capítol 4.

5.1 Mesures utilitzades

Primerament, abans de donar els resultats obtinguts a l'entrenament dels models es definiran els continguts que s'utilitzen.

5.1.1 Accuracy

L'*accuracy*, anomenada en català precisió, és una mesura utilitzada per avaluar el rendiment d'un model de classificació. Representa la proporció de prediccions correctes que el model ha realitzat sobre el total de prediccions fetes. És una de les mètriques més senzilles i comunes per avaluar models de classificació.

Una *accuracy* alta propera a 100 indica que el model és bo classificant correctament; tot i això, té certes limitacions, especialment quan es treballa amb conjunts de dades desbalancejats, on una classe és molt més freqüent que les altres. En aquests casos, un model que sempre prediu la classe majoritària pot tenir un *accuracy* alt, però no serà útil en la pràctica perquè no identificarà correctament les classes menys freqüents.

L'*accuracy* es calcula amb la següent fórmula:

$$\text{Accuracy} = \frac{\text{Número de prediccions correctes}}{\text{Total de prediccions fetes}}$$

O bé:

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}$$

On:

- VP (Veritables Positius): Nombre de casos positius correctament classificats com a positius.
- VN (Veritables Negatius): Nombre de casos negatius correctament classificats com a negatius.

- FP (Falsos Positius): Nombre de casos negatius incorrectament classificats com a positius.
- FN (Falsos Negatius): Nombre de casos positius incorrectament classificats com a negatius.

5.1.2 Precision

La *Precision*, o en català precisió, és una mètrica utilitzada en l'avaluació de models de classificació. Representa la proporció de prediccions positives correctes respecte al total de prediccions que el model ha fet com a positives. En altres paraules, la *precision* mesura quantes de les prediccions fetes pel model que van ser etiquetades com a positives realment ho eren.

Si la *precision* és alta, significa que quan el model prediu una classe positiva, té una alta probabilitat d'haver encertat (és a dir, d'haver classificat correctament). La diferència amb l'*accuracy* és que només contempla les classes positives mentre que l'*accuracy* contempla les positives i negatives.

Per tant, la precisió es calcula amb la següent fórmula:

$$\text{Precisió} = \frac{VP}{VP + FP}$$

On:

- VP (Veritables Positius): Nombre de casos positius correctament classificats com a positius.
- FP (Falsos Positius): Nombre de casos negatius incorrectament classificats com a positius.

5.1.3 Recall

El *Recall*, en català sensibilitat o veritable taxa positiva, és una mètrica utilitzada per avaluar models de classificació. Representa la proporció de casos positius reals que han estat correctament identificats pel model. És una mesura de la capacitat del model per detectar tots els casos positius dins d'un conjunt de dades.

Un *recall* alt indica que el model està identificant correctament la majoria dels casos positius (pocs falsos negatius). Això és especialment important en situacions en què és crucial detectar tots els casos positius, com en la detecció de malalties o frau. En canvi, si el *recall* és baix vol dir que el model està passant per alt molts casos positius, el que significa que hi ha un alt nombre de falsos negatius.

La fórmula pel *recall* és:

$$\text{Accuracy} = \frac{VP}{VP + FN}$$

On:

- VP (Veritables Positius): Nombre de casos positius correctament classificats com a positius.
- FN (Falsos Negatius): Nombre de casos positius incorrectament classificats com a negatius.

5.1.4 F1 Score

L'*F1 Score* és una mesura utilitzada en l'avaluació de models de classificació, especialment útil quan hi ha un desbalanceig en les classes. L'*F1 Score* combina la precisió (*precision*) i el *recall* en una única mètrica, donant una idea del rendiment del model en termes de falsos positius i falsos negatius.

L'*F1 Score* oscil·la entre 0 i 1, on 1 indica el millor rendiment possible del model (alta precisió i *recall*). Pel que un valor d'*F1 Score* baix indica que el model té problemes per identificar correctament les classes positives, o bé que està fent moltes prediccions incorrectes com a positives.

L'*F1 Score* es calcula amb la següent fórmula:

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

5.2 Models mitjançant mètriques

Per aquesta secció les mètriques que s'han utilitzat s'han extret dels documents que s'havien generat amb informació de les mètriques dels nodes i dels grafs, també s'ha fet una anàlisi general per comparar-la amb altres estratègies.

5.2.1 Anàlisi General

Primerament, s'ha dut a terme una anàlisi general, on s'ha posat com a coordenada X les dades de les carpetes combinades de l'Hospital Clínic i les provinents de Nàpols. Com a coordenada Y s'ha posat el *mstype* de *demographics.csv*. S'han utilitzat els dos models explicats prèviament. La classe 0 es refereix als controls mentre que la classe 1 es refereix als pacients que tenen EM.

SVM

S'han analitzat els conjunts de dades combinats de FA, GM i RS amb el *mstype* mitjançant una màquina de suport vectorial. S'ha analitzat l'*accuracy*, la precisió, l'*F1 score* i el *recall*. El *report* de classificació que s'ha obtingut ha estat el corresponent a la taula 5.1:

Mètrica	Accuracy	Precision		Recall		F1 Score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
FA	0.8519	0.85	0.85	0.85	0.85	0.85	0.85
GM	0.8642	0.89	0.84	0.83	0.90	0.86	0.87
RS	0.9260	0.97	0.89	0.88	0.97	0.92	0.93

Table 5.1: SVM pel anàlisi general

Primerament, per a FA, el model mostra un rendiment consistent en ambdues classes amb valors d'*accuracy*, *precision*, *recall* i *F1-Score* tots iguals al 85%. Això indica que el model és equilibrat en la seva capacitat per predir tant la classe 0 com la classe 1, però amb un rendiment global que és més aviat moderat.

Seguidament per a GM el model mostra un rendiment lleugerament millor que FA amb una *accuracy* del 86.42%. La classe 0, que és la dels controls, té una millor precisió (0.89), però un *recall* més baix (0.83), mentre que la classe 1, la dels malalts, té una precisió lleugerament inferior (0.84) però un millor *recall* (0.90). Això suggereix que GM és més equilibrat en la detecció de la classe 1, però encara presenta una petita variabilitat en la classe 0.

Per últim per a RS el model mostra el millor rendiment global, amb una *accuracy* del 92.59%. Té una precisió i un *F1-SCORE* molt alts per a ambdues classes. Especialment, el model és excel·lent en la detecció de la classe 1 (*recall* de 0.97), cosa que significa que identifica gairebé tots els casos positius correctament. Aquest model és clarament superior als altres dos en termes d'equilibri entre *precision* i *recall*.

Logistic Regression

S'ha fet el mateix estudi que anteriorment però en aquest cas utilitzant la regressió logística. El report de classificació ha estat el corresponent a la taula 5.2:

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
FA	0.8642	0.92	0.82	0.80	0.93	0.86	0.87
GM	0.9136	0.95	0.88	0.88	0.95	0.91	0.92
RS	0.9383	1.0	0.89	0.88	1.0	0.94	0.94

Table 5.2: Regressió logística pel anàlisi general

Primerament, per a FA el model mostra un bon equilibri entre les dues classes, amb una millor precisió per a la classe 0 però millor sensibilitat per a la classe 1. L'*accuracy* global és bona (86.42%), però el model tendeix a identificar millor la classe 1.

Seguidament per a GM el model presenta una millora respecte al primer, amb una *accuracy* de 91.36%. Les mètriques són equilibrades i molt bones per a ambdues classes, indicant que el model és molt eficient en la detecció i classificació de les dues classes.

Per últim, per a RS, és de nou on s'obtenen millors resultats, amb una *accuracy* de 93.83%. Té una precisió perfecta per a la classe 0 (1.00), encara que la sensibilitat és lleugerament més baixa. Per a la classe 1, la sensibilitat és màxima (1.00), la qual cosa significa que identifica correctament tots els casos de la classe 1. Aquest model és el més fiable dels tres en termes de rendiment general.

5.2.2 Anàlisi de nodes de FA

Les mètriques dels nodes que s'han utilitzat han estat el *degree*, l'*strength*, la *closeness centrality*, la *betweenness centrality* i la *eigenvector centrality*.

SVM

Utilitzant l'SVM els resultats són els corresponents a la taula 5.3:

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Degree	0.8765	0.90	0.86	0.85	0.90	0.88	0.88
Strength	0.8395	0.91	0.79	0.76	0.93	0.83	0.85
Closeness Centr.	0.8025	0.82	0.79	0.78	0.82	0.80	0.80
Betweenness Centr.	0.8642	0.88	0.85	0.85	0.88	0.86	0.86
Eigenvector Centr.	0.8395	0.89	0.80	0.78	0.90	0.83	0.85

Table 5.3: SVM per les mètriques dels nodes de FA

Com a conclusió, el model basat en *degree* va obtenir la millor *accuracy* general amb un 0.8765, mostrant un bon equilibri entre precisió i *recall* per ambdues classes. D'altra banda, el model basat en *strength* va aconseguir una alta precisió per a la classe 0 (0.91), però el seu *recall* per a la classe 1 va ser lleugerament inferior (0.85), amb una *accuracy* general de 0.8395. El model basat en *closeness centrality* va ser el més baix en rendiment, amb una *accuracy* de 0.8025 i una precisió relativament baixa per a la classe 0 (0.82). El model basat en *betweenness centrality* va obtenir una *accuracy* de 0.8642, destacant per la seva consistència en precisió i *recall* per ambdues classes. Finalment, el model basat en *eigenvector centrality* va mostrar un rendiment moderat, amb una *accuracy* de 0.8395, mantenint una precisió i *recall* relativament equilibrats per a totes dues classes. En conjunt, aquests resultats indiquen que les diferents mesures de centralitat dels nodes poden influir significativament en el rendiment dels models SVM per a la classificació de malalts i no malalts, amb *degree* i *betweenness centrality* mostrant un rendiment globalment més fort en aquesta tasca.

Logistic Regression

Utilitzant una regressió logística els resultats són els corresponents a la taula 5.4:

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Degree	0.8395	0.83	0.85	0.85	0.82	0.84	0.84
Strength	0.8272	0.83	0.82	0.83	0.82	0.83	0.82
Closeness Centr.	0.8395	0.85	0.83	0.83	0.85	0.84	0.84
Betweenness Centr.	0.8888	0.90	0.88	0.88	0.90	0.89	0.89
Eigenvector Centr.	0.8518	0.89	0.82	0.80	0.90	0.85	0.86

Table 5.4: Regressió logística per les mètriques dels nodes de FA

Com a conclusió, el model basat en *betweenness centrality* destaca com el més efectiu, amb una *accuracy* de 0.8888 i un equilibri excel·lent entre precisió, *recall* i *F1-Score* per a ambdues classes, especialment per a la detecció de malalts (classe 1) amb un *F1-Score* de 0.89. D'altra banda, els models basats en *degree* i *closeness centrality* tenen una *accuracy* de 0.8395, mantenint un rendiment acceptable, però amb limitacions en la precisió i *F1-Score*, especialment en la classe 1. El model basat en *eigenvector centrality* ofereix una *accuracy* de 0.8518, destacant-se lleugerament per sobre dels anteriors en algunes mètriques, però

sense arribar al nivell de *betweenness centrality*. Finalment, el model basat en *strength* és el que presenta el rendiment més baix, amb una *accuracy* de 0.8272, i mostra dificultats notables tant en la precisió com en el *recall* per a ambdues classes, especialment en la detecció de la classe 1. En resum, *betweenness centrality* es revela com la mesura més adequada per a la classificació de malalts i no malalts mitjançant regressió logística en aquest conjunt de dades, mentre que *strength* resulta ser la menys efectiva.

5.2.3 Anàlisi de nodes de GM

En aquest cas s'han utilitzat les dades de la substància grisa.

SVM

Utilitzant l'SVM els resultats són els corresponents a la taula 5.5:

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Degree	0.9259	0.95	0.90	0.90	0.95	0.92	0.93
Strength	0.9012	0.95	0.86	0.85	0.95	0.90	0.90
Closeness Centr.	0.8519	0.82	0.89	0.90	0.80	0.86	0.84
Betweenness Centr.	0.8765	0.92	0.84	0.83	0.93	0.87	0.88
Eigenvector Centr.	0.9259	0.97	0.89	0.88	0.97	0.92	0.93

Table 5.5: SVM per les mètriques dels nodes de GM

Com a resum, per a les dades de la substància grisa es destaca que els models basats en *degree* i *eigenvector centrality* ofereixen els millors resultats, amb una *accuracy* de 0.9259 cadascun. Aquests models mantenen un alt rendiment tant en precisió com en *recall*, aconseguint un *F1-Score* de 0.93 per a la classe 1, cosa que els fa especialment efectius per a la detecció de malalts. El model basat en *strength* també mostra un rendiment excel·lent, amb una *accuracy* de 0.9012 i un equilibri gairebé perfecte entre precisió i *recall* per a ambdues classes. Per contra, el model basat en *closeness centrality* és el que presenta el rendiment més baix, amb una *accuracy* de 0.8519 i un *F1-Score* més modest, especialment per a la classe 1. Finalment, el model basat en *betweenness centrality* ofereix un rendiment sòlid amb una *accuracy* de 0.8765, mantenint un bon equilibri entre les mètriques, però sense arribar als nivells dels models basats en *degree*, *strength*, o *eigenvector centrality*. En resum, *degree* i *eigenvector centrality* es confirmen com les millors mesures de centralitat per a la classificació de malalts en aquest conjunt de dades, mentre que *closeness centrality* és la menys efectiva.

Logistic Regression

Utilitzant una regressió logística els resultats són els corresponents a la taula 5.6:

Com a conclusió, es destaca que el model basat en *eigenvector centrality* és el més efectiu, amb una *accuracy* de 0.9383 i una precisió perfecta per a la classe 0 (1.0). Aquest model també aconsegueix un *F1-Score* molt alt de 0.94 per a la classe 1, mostrant una excel·lent capacitat de classificació tant per a malalts com per a no malalts. Els models basats en *degree*, *strength*, *closeness centrality* i *betweenness centrality* també mostren un rendiment molt bo, amb *accuracies* que oscil·len entre 0.9136 i 0.9259, i mantenint un

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Degree	0.9259	0.97	0.89	0.88	0.97	0.92	0.93
Strength	0.9136	0.97	0.87	0.85	0.97	0.91	0.92
Closeness Centr.	0.9012	0.92	0.88	0.88	0.93	0.90	0.90
Betwenness Centr.	0.9136	0.97	0.87	0.85	0.97	0.91	0.92
Eigenvector Centr.	0.9383	1.0	0.89	0.88	1.0	0.94	0.94

Table 5.6: Regressió logística per les mètriques dels nodes de GM

equilibri excel·lent entre precisió, *recall* i *F1-Score* per a ambdues classes. Particularment, els models basats en *strength* i *betweenness centrality* comparteixen una *accuracy* de 0.9136, destacant per un alt *F1-Score* de 0.92 per a la classe 1, cosa que els fa molt fiables per a la detecció de casos positius. En resum, *eigenvector centrality* es presenta com la millor mesura de centralitat per a la classificació mitjançant regressió logística en aquest conjunt de dades, oferint el rendiment més consistent i alt en totes les mètriques considerades, mentre que les altres mesures també ofereixen resultats molt competitius.

5.2.4 Anàlisi de nodes de RS

En aquest cas s'han utilitzat les dades en estat de repòs.

SVM

Utilitzant l'SVM els resultats són els corresponents a la taula 5.7:

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Degree	0.7407	0.71	0.79	0.83	0.65	0.76	0.71
Strength	0.6666	0.63	0.72	0.80	0.53	0.71	0.61
Closeness Centr.	0.8765	0.84	0.92	0.93	0.82	0.88	0.87
Betwenness Centr.	0.6790	0.67	0.68	0.71	0.65	0.69	0.67
Eigenvector Centr.	0.6666	0.67	0.67	0.68	0.65	0.67	0.66

Table 5.7: SVM per les mètriques dels nodes de RS

En l'anàlisi dels models SVM aplicats al conjunt de dades RS, s'observa que el model basat en *closeness centrality* és el que ofereix el millor rendiment, amb una *accuracy* de 0.8755 i un *F1-Score* equilibrat per a ambdues classes, destacant especialment en la detecció de malalts (classe 1) amb un *F1-Score* de 0.87. Els models basats en *degree* i *betweenness centrality* ofereixen un rendiment moderat, amb *accuracy* de 0.7407 i 0.6790, respectivament, mantenint un equilibri acceptable entre precisió i *recall*, però sense arribar al nivell de *closeness centrality*. D'altra banda, els models basats en *strength* i *eigenvector centrality* tenen el rendiment més baix, amb una *accuracy* de 0.6666 cadascun, i presenten dificultats per identificar correctament la classe 1, tal com es reflecteix en els seus *F1-Scores* més baixos. En resum, *closeness centrality* és la mesura més efectiva per a la classificació de malalts i no malalts en aquest conjunt de dades, mentre que *strength* i *eigenvector centrality* són les menys eficients.

Logistic Regression

Utilitzant una regressió logística els resultats són els corresponents a la taula 5.8:

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Degree	0.7777	0.74	0.82	0.85	0.70	0.80	0.86
Strength	0.6914	0.66	0.74	0.80	0.57	0.73	0.65
Closeness Centr.	0.8519	0.84	0.87	0.88	0.82	0.86	0.85
Betweenness Centr.	0.753	0.76	0.75	0.76	0.75	0.76	0.75
Eigenvector Centr.	0.7407	0.72	0.77	0.80	0.68	0.76	0.72

Table 5.8: Regressió logística per les mètriques dels nodes de RS

Com a conclusió, *closeness centrality* és el que mostra el millor rendiment global, amb una *accuracy* de 0.8519 i un bon equilibri entre precisió, *recall* i *F1-Score* per a ambdues classes, especialment destacant-se en la identificació de malalts (classe 1) amb un *F1-Score* de 0.86. Per contra, el model basat en *strength* és el que presenta el rendiment més baix, amb una *accuracy* de 0.6914 i un *F1-Score* molt baix de 0.65 per a la classe 1, indicant dificultats importants en la classificació correcta dels casos positius.

Els models basats en *degree*, *betweenness centrality*, i *eigenvector centrality* presenten un rendiment intermedi, amb accuracies al voltant de 0.7407 a 0.7777, però amb limitacions evidents en el *recall* i *F1-Score*, especialment per a la classe 1, cosa que suggereix una menor efectivitat en la detecció de malalts. En resum, mentre que *closeness centrality* sembla ser la millor opció per a la classificació mitjançant regressió logística en aquest conjunt de dades, les altres mesures de centralitat mostren un rendiment inferior, amb *strength* sent la menys efectiva per a la tasca de classificació de malalts.

5.2.5 Anàlisi de grafs de FA

Les mètriques dels grafs que s'han utilitzat han estat l'*average degree*, l'*average clustering* i la *density*.

SVM

Utilitzant l'SVM els resultats són els corresponents a la taula 5.9:

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Av Degree	0.9259	1.0	0.87	0.85	1.0	0.92	0.93
Av Clustering	0.8888	0.94	0.84	0.83	0.95	0.88	0.89
Density	0.9259	1.0	0.87	0.85	1.0	0.92	0.93

Table 5.9: SVM per les mètriques dels grafs de FA

Com a conclusió, s'observa que les mesures *average degree* i *density* ofereixen els millors rendiments, amb una *accuracy* general de 0.9259 cadascuna. Aquests models també mostren una precisió perfecta per a la classe 0 (1.0) i un excel·lent equilibri entre *recall* i *F1-Score*

per a ambdues classes, aconseguint un *F1-Score* de 0.93 per a la classe 1, la qual cosa indica una alta capacitat de detecció tant de malalts com de no malalts. La mètrica *average clustering* presenta un rendiment lleugerament inferior, amb una *accuracy* de 0.8888 i un *F1-Score* de 0.89 per a la classe 1, tot i que segueix mantenint una precisió i *recall* robustos.

Logistic Regression

Utilitzant una regressió logística els resultats són els corresponents a la taula 5.10:

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Av Degree	0.9136	0.97	0.85	0.85	0.97	0.91	0.92
Av Clustering	0.8519	0.87	0.83	0.83	0.88	0.85	0.85
Density	0.9136	0.97	0.87	0.85	0.97	0.91	0.92

Table 5.10: Regressió logística per les mètriques dels grafs de FA

En resum, les mesures *average degree* i *density* es destaquen com les més efectives, amb una *accuracy* general de 0.9136 cadascuna. Aquests models mostren un alt rendiment en totes les mètriques, amb una precisió de 0.97 per a la classe 0 i un *F1-Score* de 0.92 per a la classe 1, indicant una excel·lent capacitat de classificació tant per a malalts com per a no malalts. D'altra banda, la mètrica *average clustering* presenta un rendiment inferior, amb una *accuracy* de 0.8519 i un *F1-Score* de 0.85 per a la classe 1, tot i mantenir una bona precisió i *recall*, però sense arribar al nivell de les altres dues mètriques.

5.2.6 Anàlisi de grafs de GM

SVM

Utilitzant l'SVM els resultats són els corresponents a la taula 5.11:

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Av Degree	0.9012	1.0	0.83	0.80	1.0	0.89	0.91
Av Clustering	0.8765	1.0	0.80	0.76	1.0	0.86	0.89
Density	0.9012	1.0	0.83	0.80	1.0	0.89	0.91

Table 5.11: SVM per les mètriques dels grafs de GM

En resum, les mesures *average degree* i *density* mostren rendiments molt similars i alts, amb una *accuracy* general de 0.9012 cadascuna. Ambdues mètriques aconsegueixen una precisió perfecta per a la classe 0 (1.0) i un equilibri consistent entre *recall* i *F1-Score* per a ambdues classes, amb un *F1-Score* de 0.91 per a la classe 1. Això indica que aquests models són molt efectius en la classificació tant de malalts com de no malalts. D'altra banda, la mètrica *average clustering* presenta un rendiment lleugerament inferior, amb una *accuracy* de 0.8765 i un *F1-Score* de 0.89 per a la classe 1, mantenint encara una bona precisió i *recall*, però amb una menor capacitat de detecció comparada amb les altres dues mètriques.

Logistic Regression

Utilitzant una regressió logística els resultats són els corresponents a la taula 5.12:

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Av Degree	0.9012	1.0	0.83	0.80	1.0	0.89	0.91
Av Clustering	0.9012	1.0	0.83	0.80	1.0	0.89	0.91
Density	0.9012	1.0	0.83	0.80	1.0	0.89	0.91

Table 5.12: Regressió logística per les mètriques dels grafs de GM

En conclusió, les tres mesures avaluades (*average degree*, *average clustering* i *density*) mostren un rendiment idèntic en termes d'accuracy general, amb un valor de 0.9012 cadascuna. Totes les mètriques aconseguixen una precisió perfecta per a la classe 0 (1.0) i un bon equilibri entre *recall* i *F1-Score* per a ambdues classes, amb un *F1-Score* de 0.91 per a la classe 1. Això indica que aquestes mètriques són igualment efectives en la classificació tant de malalts com de no malalts quan s'utilitza regressió logística. Tot i que totes les mètriques ofereixen un rendiment alt i consistent, no hi ha una diferència clara que faci que una d'elles sobresurti significativament sobre les altres en aquest conjunt específic d'anàlisi.

5.2.7 Anàlisi de grafs de RS

SVM

Utilitzant l'SVM els resultats són els corresponents a la taula 5.13:

Mètrica	Accuracy	Precisió		Recall		F1 score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Av Degree	0.8765	0.88	0.88	0.88	0.88	0.88	0.88
Av Clustering	0.7531	0.82	0.71	0.66	0.85	0.73	0.77
Density	0.8765	0.88	0.88	0.88	0.88	0.88	0.88

Table 5.13: SVM per les mètriques dels grafs de RS

En resum, cal destacar que les mesures *average degree* i *density* ofereixen els millors rendiments, amb una *accuracy* general de 0.8765 cadascuna. Ambdues mètriques mostren un equilibri consistent entre precisió, *recall* i *F1-Score* per a ambdues classes, aconseguint un *F1-Score* de 0.88 per a la classe 1, indicant una bona capacitat per classificar tant malalts com no malalts. D'altra banda, la mètrica *average clustering*, de nou, presenta un rendiment inferior, amb una *accuracy* de 0.7531 i un *F1-Score* de 0.77 per a la classe 1, reflectint una menor efectivitat en la detecció de casos positius en comparació amb les altres dues mètriques.

Logistic Regression

Utilitzant una regressió logística els resultats són els corresponents a la taula 5.14:

En conclusió, s'observa que les mesures *average degree* i *density* ofereixen un rendiment superior, amb una *accuracy* general de 0.8612 cadascuna. Ambdues mètriques mostren un bon equilibri entre precisió, *recall* i *F1-Score* per a ambdues classes, amb un *F1-Score* de 0.86 per a la classe 1, indicant una capacitat efectiva per classificar tant malalts com no

Mètrica	Accuracy	Precisió	Recall		F1 score		
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
Av Degree	0.8642	0.86	0.87	0.88	0.85	0.87	0.86
Av Clustering	0.7654	0.79	0.74	0.73	0.80	0.76	0.77
Density	0.8642	0.86	0.87	0.88	0.85	0.87	0.86

Table 5.14: Regressió logística per les mètriques dels grafs de RS

malalts. En canvi, la mètrica *average clustering* presenta un rendiment inferior, amb una *accuracy* de 0.7654 i un *F1-Score* de 0.77 per a la classe 1, reflectint una menor efectivitat en la detecció de casos positius comparada amb les altres dues mètriques. Per tant, *average degree* i *density* es consoliden com les mètriques més eficients per a la classificació amb regressió logística, mentre que *average clustering* mostra un rendiment notablement inferior, especialment en la detecció de malalts.

5.3 Embeddings

Posteriorment, s'han fet *embeddings* per individu utilitzant *RandomWalk* i *DeepWalk*, de dues formes diferents: utilitzant el *Word2Vec* i mitjançant el *Node2Vec* i s'han aplicat als models. A més s'han guardat els resultats d'aquests *embeddings* en documents per poder-los utilitzar després.

5.3.1 Word2Vec

S'han aplicat els models previs, la màquina de vector de suport i la regressió logística, als *embeddings* generats mitjançant el *Word2Vec*.

SVM

Utilitzant l'SVM els resultats dels *embeddings* creats mitjançant el *Word2Vec* de FA, GM i RS són els corresponents a la taula 5.15:

Mètrica	Accuracy	Precision		Recall		F1 Score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
FA	0.8888	0.96	0.85	0.76	0.98	0.85	0.91
GM	0.9136	1.00	0.87	0.79	1.00	0.89	0.93
RS	0.7407	0.68	0.80	0.74	0.74	0.70	0.77

Table 5.15: SVM pels embeddings amb *Word2Vec*

En resum, GM destaca per tenir el millor rendiment global amb una *accuracy* de 0.9136 i una precisió perfecta per a la Classe 0, això indica que el model és molt efectiu en la predicció d'aquesta classe, capturant correctament la majoria dels exemples, a més de tenir un *recall* també perfecte a la Classe 1. Mentre que FA també presenta bons resultats amb una *accuracy* de 0.8888 i un equilibri adequat entre precisió i *recall*. En canvi, RS té el rendiment més baix amb una *accuracy* de 0.7407, indicant que el model té més dificultats per predir correctament aquesta classe.

Logistic Regression

Utilitzant una regressió logística els resultats són els corresponents a la taula 5.15:

Mètrica	Accuracy	Precision		Recall		F1 Score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
FA	0.8765	0.93	0.85	0.76	0.96	0.84	0.90
GM	0.9136	1.00	0.87	0.79	1.00	0.89	0.93
RS	0.7654	0.76	0.77	0.65	0.85	0.70	0.81

Table 5.16: Regressió logística pels embeddings amb *Word2Vec*

En resum, GM mostra el millor rendiment, amb una *accuracy* de 0.9136, destacant per tenir una precisió perfecta (1.00) per a la Classe 0 i un alt *recall* i *F1 Score* per a la Classe 1, similars als resultats observats en el model SVM. FA, amb una *accuracy* de 0.8765, també mostra un bon rendiment global, tot i que lleugerament inferior al de GM, amb una precisió de 0.93 per a la Classe 0 i un bon *recall* per a la Classe 1 (0.96). Finalment, RS continua presentant els resultats més baixos, amb una *accuracy* de 0.7654, però amb una millora en el *recall* de la Classe 1 (0.85) respecte al model SVM, encara que les altres mètriques són inferiors, indicant que aquest model també té dificultats per predir correctament aquesta classe, tot i ser lleugerament més precís en algunes àrees específiques.

5.3.2 Node2Vec

Seguidament, s'han aplicat els models previs, la màquina de vector de suport i la regressió logística, als *embeddings* generats mitjançant el *Node2Vec*.

SVM

Utilitzant l'SVM els resultats dels *embeddings* creats mitjançant el *Node2Vec* de FA, GM i RS són els corresponents a la taula 5.17:

Mètrica	Accuracy	Precision		Recall		F1 Score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
FA	0.8888	0.88	0.90	0.85	0.91	0.87	0.91
GM	0.9136	1.00	0.87	0.79	1.00	0.89	0.93
RS	0.7037	0.68	0.72	0.56	0.81	0.61	0.76

Table 5.17: SVM pels embeddings amb *Node2Vec*

En resum, GM mostra el millor rendiment amb una *accuracy* de 0.9136, mantenint una precisió perfecta (1.00) per a la Classe 0 i un alt *recall* i *F1 Score* per a la Classe 1, de nou. FA també presenta un bon rendiment, amb una *accuracy* de 0.8888, una precisió i *recall* equilibrats, especialment per a la Classe 1, on el model té un *recall* i un *F1 Score* de 0.91, indicant que el model és consistent en la predicció de FA. D'altra banda, RS té el rendiment més baix, amb una *accuracy* de 0.7037, i les mètriques de precisió, *recall* i *F1 Score* més baixes, particularment per a la Classe 0, on el *recall* és de només 0.56 i el *F1 Score* és de 0.61.

Logistic Regression

Utilitzant una regressió logística els resultats són els corresponents a la taula 5.15:

Mètrica	Accuracy	Precision		Recall		F1 Score	
Classe	General	Classe 0	Classe 1	Classe 0	Classe 1	Classe 0	Classe 1
FA	0.8765	0.85	0.89	0.85	0.89	0.85	0.89
GM	0.9136	1.00	0.87	0.79	1.00	0.89	0.93
RS	0.7037	0.69	0.71	0.53	0.83	0.60	0.76

Table 5.18: Regressió logística pels embeddings amb *Node2Vec*

En resum, GM destaca amb la millor *accuracy* (0.9136) i una precisió perfecta per a la Classe 0 (1.00), demostrant que el model és molt efectiu en la predicció d'aquesta classe. A més, el *recall* i *F1 Score* per a la Classe 1 també són alts, indicant una forta capacitat del model per identificar correctament els exemples d'aquesta classe. FA, amb una *accuracy* de 0.8765, també mostra un bon rendiment, especialment amb una precisió de 0.89 per a la Classe 1 i un *recall* de 0.85, cosa que indica que el model té un bon equilibri en la predicció de les dues classes. D'altra banda, RS té, de nou, el rendiment més baix, amb una *accuracy* de 0.7037 i les mètriques de precisió, *recall* i *F1 Score* més baixa, sobretot per a la Classe 0, on el *recall* és només de 0.53 i el *F1 Score* de 0.60.

5.4 GCN

Finalment, s'han aplicat diferents dades per veure els resultats mitjançant una *Graph Convolutional Network*. Primerament, s'han introduït els documents de les diferents mètriques dels nodes i dels grafs i després els dos tipus d'embeddings: els generats mitjançant *Word2Vec* i els de *Node2Vec*.

Mitjançant una GCN s'han dut a terme tests AUC entrenats en tres *folds* diferents cada un amb un conjunt de dades de train i test amb la mateixa mida i percentatge de classes positives que sempre és el 0.544 (54%, el percentatge de persones amb EM que hi ha a les dades).

5.4.1 Anàlisi de nodes

A la taula 5.19 es mostren els resultats del test AUC en importar-li els documents amb les mètriques dels nodes a la GCN:

	Degree	Strength	Closeness Centr.	Betweenness Centr.	Eigenvector Centr.
FA	0.50	0.50	1.00	1.00	1.00
GM	1.00	0.98	0.98	0.98	0.98
RS	0.50	0.50	0.89	0.90	0.90

Table 5.19: AUC (GCN) per les mètriques dels nodes

GM destaca amb els valors més alts en la majoria de mètriques, amb un *Degree* d'1.00 i la resta de mètriques de 0.98, indicant que els nodes de GM tenen una connectivitat i

influència gairebé màxima en la xarxa.

FA té un *degree* i una *strength* de 0.50, però valors màxims en *closeness*, *betweenness*, i *eigenvector centrality*. Això indica que, tot i tenir menys connexions directes, els nodes de FA són molt centrals i crucials per la connectivitat i distribució d'informació dins la xarxa.

RS presenta valors similars a FA en *degree* i *strength* (0.50), però amb una influència lleugerament inferior en la resta de mètriques, suggerint que els nodes de RS són menys centrals i influents que els de GM i FA, tot i mantenir una certa importància en la xarxa.

5.4.2 Anàlisi de grafs

A la taula 5.20 es mostren els resultats del test AUC en importar-li els documents amb les mètriques dels grafs a la GCN:

	Av. Degree	Av. Clustering	Density
FA	0.50	0.50	0.50
GM	1.00	1.00	1.00
RS	0.57	0.50	0.57

Table 5.20: AUC (GCN) per les mètriques dels grafs

Els grafs de GM tenen els valors més alts en totes les mètriques amb un 1.0 en totes les mètriques. Això indica que, de mitjana, els grafs corresponents a GM estan completament connectats, amb tots els nodes interconnectats i formant clústers perfectes, suggerint una estructura de xarxa molt densa i altament cohesionada.

D'altra banda, els grafs de FA i RS mostren unes mètriques al voltant del 0.5. Aquests valors indiquen que, de mitjana, els grafs d'RS tenen una connectivitat moderada, amb un grau mitjà lleugerament superior al de FA, però amb una densitat i un *Average Clustering* que no arriben al nivell de GM. Això suggereix que els grafs de RS estan més connectats que els de FA, però no tan densament com els de GM.

5.4.3 Embeddings Word2Vec i Node2Vec

Finalment, s'han aplicat els documents que contenen els *embeddings* que s'han generat anteriorment. Els resultats corresponen a la taula 5.21:

	Word2Vec	Node2Vec
FA	1.00	1.00
GM	0.98	0.98
RS	0.89	0.88

Table 5.21: AUC (GCN) pels embeddings de Word2Vec i Node2Vec

En resum, es pot observar una puntuació perfecta pels dos *embeddings* a FA (1.00), millor que GM, per primer cop, ja que GM té una puntuació quasi perfecta (0.98), coincidint també en el fet que els dos *embeddings* tenen la mateixa puntuació. D'altra banda, RS té una puntuació lleugerament superior en l'embedding creat mitjançant el *Word2Vec* (0.89), mentre que en el de *Node2Vec* és de 0.88.

Chapter 6

Conclusions

En aquest treball s'han analitzat dades d'Anisotropia Fraccional (FA), Substància grisa (GM) i Estat de Repòs (RS) de 270 participants, dels quals 123 participants eren controls i 147 eren pacients d'Esclerosi Múltiple.

Aquestes dades són rellevants perquè un valor alt de FA indica una alta coherència en la direccionalitat de la difusió de l'aigua en la matèria blanca, suggerint una integritat òptima dels axons i les seves beines de mielina; en l'Esclerosi Múltiple, valors alts de FA poden reflectir àrees del cervell no afectades per la malaltia, mentre que valors baixos s'associen amb desmielinització, indicant danys a la matèria blanca. A més, la substància grisa, responsable de funcions cognitives com la memòria i l'atenció, també pateix degeneració en l'EM, contribuint a la discapacitat cognitiva. Finalment, l'anàlisi de l'estat de repòs permet detectar alteracions en la connectivitat cerebral, essencial per comprendre completament l'impacte de l'EM, ja que aquestes disfuncions es relacionen amb símptomes com la fatiga i la depressió.

Primerament, s'han extret les mètriques dels nodes i dels grafs i s'han analitzat mitjançant una màquina de vectors de suport i una regressió logística, si es comparen aquests dos algorismes SVM en general mostra un rendiment lleugerament millor a través de les mètriques, especialment en termes de precisió i *recall*. No obstant això, la Regressió Logística també rendeix bé, amb alguns casos on supera SVM, especialment en GM, on iguala o supera totes les *accuracy*. Tots dos classificadors demostren un rendiment consistent a través dels diferents conjunts de característiques (FA, GM, RS), amb GM mostrant el millor rendiment i RS el pitjor.

Sobre l'anàlisi a les mètriques dels nodes cal destacar, sobretot, a FA el *degree* quan s'utilitza la SVM i la *betweenness centrality* quan s'utilitza la regressió logística, a GM cal destacar la millora que fa la regressió logística i a RS cal destacar la *closeness centrality*. Sobre els grafs cal destacar que l'*average clustering* és sempre pitjor que els altres excepte en la regressió logística de GM, i que les *accuracy* són molt elevades, per tant, es pot observar un bon rendiment general.

Posteriorment, s'han fet els embeddings mitjançant *Word2Vec* i *Node2Vec*. Comparat amb el resultat obtingut en aplicar el conjunt de dades directament a una SVM o regressió logística, RS empitjora molt, sobretot al *Node2Vec*, en canvi, FA i GM fan el contrari, i obtenen el mateix resultat als dos *embeddings* (*Word2Vec* i *Node2Vec*). Aquesta millora és sobretot destacable a l'SVM.

Finalment, s'ha utilitzat una *Graph Convolutional Netwrok*, a la qual se li han aplicat tots els documents dels nodes i dels grafs. Als nodes destaca especialment GM que té totes les mètriques amb una puntuació perfecta o quasi. D'altra banda, FA té tres mètriques amb una puntuació perfecta i dues amb un 0.50 com les té RS, però les altres tres tot i que són bones no arriben a ser perfectes. Als grafs destaca GM amb una puntuació perfecta a les tres mètriques i FA obté uns resultats terribles tenint 0.50 a les tres. RS funciona una mica millor, però no prou.

A la GCN també se li han aplicat els documents que contenen els *embeddings* del *Word2Vec* i *Node2Vec*, els quals han obtingut molt bons resultats tenint una puntuació perfecta a FA i quasi perfecta a GM, RS és l'única en la qual hi ha una diferència d'una centèsima en la qual *Word2Vec* supera a *Node2Vec*, com ja passava quan s'ha fet una SVM i regressió logística als *embeddings* originals. Tot i això, RS amb la GCN d'*embeddings* supera els resultats que s'havien obtingut recentment.

En resum, el millor resultat que s'ha obtingut per a FA ha estat en aplicar els *embeddings* de *Word2Vec* i *Node2Vec* a la GCN, en tots dos s'ha obtingut una puntuació d'1.00 en l'AUC, el que ha estat sorprenent, ja que les mètriques de FA a la GCN han donat 0.50 les tres. El millor resultat que s'ha obtingut per a GM ha estat també mitjançant la GCN, però de forma més general: tot i que tots els resultats de GM han estat força bons, aquests han destacat, ja que als nodes tenien una mètrica amb 1.00 i la resta amb 0.98 i als grafs tenien totes tres amb 1.00, a més, als *embeddings* el resultat de l'AUC ha estat 0.98 per tots dos. Per últim, RS ha estat la més decebedora perquè és en general la que ha donat pitjors resultats. Tot i això, el resultat general d'haver fet una SVM i una LR sobre les dades inicials ha estat el més positiu amb una *accuracy* de 0.9260 superant a FA i a GM, els resultats dels *embeddings* a la GCN tampoc han estat decebedors, ja que l'AUC marcava 0.89 al *Word2Vec* i 0.88 al *Node2Vec*.

Per concloure, com era d'esperar els *embeddings* combinats amb la GCN han estat els que han donat millor resultats, amb uns resultats quasi perfectes, el que afirma que hi ha una correlació entre l'Esclerosi Múltiple i les diferents dades que s'han utilitzat i, per tant, existeixen patrons que poden ser utilitzats per detectar la presència de la malaltia.

Com a futura aplicació d'aquest treball estaria molt interessant veure si canvien els resultats en utilitzar *GraphSAGE*, ja que utilitza funcions d'agregació que es poden ajustar i el fan més flexible i adaptatiu als diferents tipus de grafs a diferència de la GCN que és més rígida atès el seu funcionament mitjançant operacions de convolució, i potser podria proporcionar millor resultats en la classificació de RS.

Chapter 7

References

- [1] Labonne, M. (2023). *Hands-on graph neural networks using Python: practical techniques and architectures for building powerful graph and deep learning apps with Pytorch*. Packt Publishing. ISBN: 978-1804617526. Disponible a: <https://github.com/PacktPublishing/Hands-On-Graph-Neural-Networks-Using-Python>.
- [2] Casas-Roma, J., Martinez-Heras, E., Solé-Ribalta, A., Solana, E., Lopez-Soley, E., Vivó, F., Diaz-Hurtado, M., Alba-Arbalat, S., Sepulveda, M., Blanco, Y., Saiz, A., Borge-Holthoefer, J., Llufríu, S., & Prados, F. (2022). Applying multilayer analysis to morphological, structural, and functional brain networks to identify relevant dysfunction patterns. *Network Neuroscience*. Disponible a: <https://direct.mit.edu/netn/article/6/3/916/111665/Applying-multilayer-analysis-to-morphological>.
- [3] Solana, E., Martinez-Heras, E., Casas-Roma, J., Calvet, L., Lopez-Soley, E., Sepulveda, M., Sola-Valls, N., Montejo, C., Blanco, Y., Pulido-Valdeolivas, I., Andorra, M., Saiz, A., Prados, F., & Llufríu, S. (2019). Modified connectivity of vulnerable brain nodes in multiple sclerosis, their impact on cognition and their discriminative value. *Scientific Reports*. Disponible a: <https://www.nature.com/articles/s41598-019-56806-z>.
- [4] Lozano-Bagén, T., Martinez-Heras, E., Solana, E., Garrido-Romero, S., Llufríu, S., Prados, F., & Casas-Roma, J. (2023). Characterization of Brain Networks through the lens of Persistent Homology. *Pending publication or journal placeholder*.
- [5] Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273-297. Disponible a: <https://link.springer.com/article/10.1007/BF00994018>.
- [6] Cox, D. R. (1958). The regression analysis of binary sequences. *Journal of the Royal Statistical Society: Series B (Methodological)*, 20(2), 215-232. Disponible a: <https://www.jstor.org/stable/2983890>.
- [7] Bengio, Y., Ducharme, R., Vincent, P., & Jauvin, C. (2003). A neural probabilistic language model. *Journal of Machine Learning Research*, 3(Feb), 1137-1155. Disponible a: <http://www.jmlr.org/papers/v3/bengio03a.html>.
- [8] Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*. Disponible a: <https://arxiv.org/abs/1301.3781>.
- [9] Grover, A., & Leskovec, J. (2016). node2vec: Scalable feature learning for networks. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Dis-*

- covery and Data Mining*, 855-864. Disponible a: <https://dl.acm.org/doi/10.1145/2939672.2939754>.
- [10] Pólya, G. (1921). Über eine Aufgabe der Wahrscheinlichkeitsrechnung betreffend die Irrfahrt im Straßennetz. *Mathematische Annalen*, 84(1-2), 149-160. Disponible a: <https://link.springer.com/article/10.1007/BF01458701>.
- [11] Perozzi, B., Al-Rfou, R., & Skiena, S. (2014). DeepWalk: Online learning of social representations. *Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 701-710. Disponible a: <https://dl.acm.org/doi/10.1145/2623330.2623732>.
- [12] Scarselli, F., Gori, M., Tsoi, A. C., Hagenbuchner, M., & Monfardini, G. (2009). The graph neural network model. *IEEE Transactions on Neural Networks*, 20(1), 61-80. Disponible a: <https://ieeexplore.ieee.org/document/4699608>.
- [13] Kipf, T. N., & Welling, M. (2017). Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*. Disponible a: <https://arxiv.org/abs/1609.02907>.
- [14] Hamilton, W. L., Ying, R., & Leskovec, J. (2017). Inductive representation learning on large graphs. *Advances in Neural Information Processing Systems*, 30, 1024-1034. Disponible a: https://proceedings.neurips.cc/paper_files/paper/2017/file/5dd9db5e033da9c6fb5ba83c7a7ebea9-Paper.pdf.
- [15] Scikit-learn. *f1_score* - *Scikit-learn*. Disponible a: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html.
- [16] Scikit-learn. *precision_score* - *Scikit-learn*. Disponible a: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.precision_score.html.
- [17] Scikit-learn. *recall_score* - *Scikit-learn*. Disponible a: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.recall_score.html.
- [18] Scikit-learn. *accuracy_score* - *Scikit-learn*. Disponible a: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.accuracy_score.html.
- [19] Datacamp. *Comprehensive Introduction to Graph Neural Networks (GNNs) Tutorial*. Disponible a: <https://www.datacamp.com/tutorial/comprehensive-introduction-graph-neural-networks-gnns-tutorial>.
- [20] ResearchGate. *Illustration of sampling and aggregation in Graph-SAGE method*. Disponible a: https://www.researchgate.net/figure/Illustration-of-sampling-and-aggregation-in-GraphSAGE-method-A-sample-of-neighboring_fig1_351575091.
- [21] Towards Data Science. *Graph Convolutional Networks: Introduction to GNNs*. Disponible a: <https://towardsdatascience.com/graph-convolutional-networks-introduction-to-gnns-24b3f60d6c95>.
- [22] Geekflare. *Graph Neural Networks*. Disponible a: <https://geekflare.com/graph-neural-networks/>.

-
- [23] Espindola, G. *Què són els embeddings i com s'utilitzen en la intel·ligència artificial amb Python*. Disponible a: <https://gustavo-espindola.medium.com/qu%C3%A9-son-los-embeddings-y-c%C3%B3mo-se-utilizan-en-la-inteligencia-artificial-con-python-45b751ed86a5>.
 - [24] Abhyuday, T. *DeepWalk and Node2Vec: Graph Embeddings*. Disponible a: <https://medium.com/@tejpai.abhyuday/deep-walk-and-node2vec-graph-embeddings-faf02d369442>.
 - [25] GeeksforGeeks. *Random Walk*. Disponible a: <https://www.geeksforgeeks.org/random-walk/>.
 - [26] Towards Data Science. *Logistic Regression Explained*. Disponible a: <https://towardsdatascience.com/logistic-regression-explained-9ee73cede081>.
 - [27] Viquipèdia. *Màquina de vector de suport*. Disponible a: https://ca.wikipedia.org/wiki/M%C3%A0quina_de_vector_de_suport.
 - [28] Viquipèdia. *Regressió logística*. Disponible a: https://ca.wikipedia.org/wiki/Regressi%C3%B3_log%C3%A0stica.
 - [29] MathWorks. *Support Vector Machine*. Disponible a: <https://es.mathworks.com/discovery/support-vector-machine.html>.
 - [30] National Multiple Sclerosis Society. *Definition of MS*. Disponible a: <https://www.nationalmssociety.org/What-is-MS/Definition-of-MS>.
 - [31] Mayo Clinic. *Multiple Sclerosis: Symptoms & Causes*. Disponible a: <https://www.mayoclinic.org/diseases-conditions/multiple-sclerosis/symptoms-causes/syc-20350269>.
 - [32] MSIF. *About MS*. Disponible a: <https://www.msif.org/about-ms/>.
 - [33] Scikit-learn. *OneToOneFeatureMixin*. Disponible a: <https://scikit-learn.org/stable/modules/generated/sklearn.base.OneToOneFeatureMixin.html>.
 - [34] Scikit-learn. *Support Vector Machines*. Disponible a: <https://scikit-learn.org/stable/modules/svm.html>.
 - [35] Scikit-learn. *Logistic Regression*. Disponible a: https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression.
 - [36] NetworkX. *NetworkX: Overview*. Disponible a: <https://networkx.org/>.
 - [37] NetworkX. *Graph.degree*. Disponible a: <https://networkx.org/documentation/stable/reference/classes/generated/networkx.Graph.degree.html>.
 - [38] NetworkX. *Average Clustering*. Disponible a: https://networkx.org/documentation/stable/reference/algorithms/generated/networkx.algorithms.cluster.average_clustering.html.
 - [39] NetworkX. *Density Function*. Disponible a: <https://networkx.org/documentation/stable/reference/generated/networkx.classes.function.density.html>.

- [40] NetworkX. *Betweenness Centrality in Bipartite Graphs*. Disponible a: <https://networkx.org/documentation/stable/reference/algorithms/generated/networkx.algorithms.bipartite centrality.betweenness centrality.html#networkx.algorithms.bipartite centrality.betweenness centrality>.
- [41] NetworkX. *Degree Centrality in Bipartite Graphs*. Disponible a: <https://networkx.org/documentation/stable/reference/algorithms/generated/networkx.algorithms.bipartite centrality.degree centrality.html#networkx.algorithms.bipartite centrality.degree centrality>.
- [42] NetworkX. *Closeness Centrality in Bipartite Graphs*. Disponible a: <https://networkx.org/documentation/stable/reference/algorithms/generated/networkx.algorithms.bipartite centrality.closeness centrality.html#networkx.algorithms.bipartite centrality.closeness centrality>.

Appendix A

CODI

Per qualsevol consulta al codi, a les dades, o als documents que va generant el codi, es pot trobar aquí: [GitHub](#)